

**UNIVERZITET U BIHAĆU
TEHNIČKI FAKULTET
BIHAĆ**

ZAVRŠNI DIPLOMSKI RAD

**RAZVOJ WEB APLIKACIJE SA AI PODRŠKOM ZA KREIRANJE I
ANALIZU CV-a, TE PERSONALIZOVANU PREPORUKU
POSLOVA**

Bajrektarević Azra

Bihać, maj 2026.

RAZVOJ WEB APLIKACIJE SA AI PODRŠKOM ZA KREIRANJE I ANALIZU CV-a, TE PERSONALIZOVANU PREPORUKU POSLOVA

SAŽETAK:

Cilj ovog završnog rada bio je projektovati i razviti web aplikaciju s podrškom umjetne inteligencije koja omogućava kreiranje, analizu i unapređenje CV-a, kao i personalizovanu preporuku poslova. Rad polazi od analize problema s kojima se suočavaju kandidati za zaposlenje, uključujući nedostatak znanja u izradi kvalitetnog CV-a, preopterećenost informacijama prilikom pretrage poslova te ograničenu dostupnost profesionalnih usluga karijernog savjetovanja. Također su analizirana postojeća digitalna rješenja i identifikovana njihova ograničenja, posebno u pogledu fragmentiranosti i nedostatka personalizacije. Na osnovu provedene analize definisani su funkcionalni i nefunkcionalni zahtjevi sistema, te je dizajnirana arhitektura aplikacije zasnovana na MERN tehnološkom steoku. Razvijeni sistem obuhvata module za upravljanje korisnicima, izradu CV-a, analizu CV-a korištenjem AI tehnologija te preporuku poslova putem integracije eksternih API servisa. Vrijednost rada ogleda se u primjeni AI modela za obradu prirodnog jezika, koji omogućavaju semantičku analizu sadržaja CV-a, generisanje preporuka za unapređenje i povezivanje korisničkog profila s relevantnim radnim pozicijama. Razvijeno rješenje predstavlja funkcionalnu platformu koja doprinosi unapređenju procesa zapošljavanja i kvaliteta CV dokumenata.

Ključne riječi: *Umjetna inteligencija; Web aplikacija; Analiza CV-a; Personalizovana preporuka poslova; Obrada prirodnog jezika*

DEVELOPMENT OF A WEB APPLICATION WITH AI SUPPORT FOR CV CREATION, ANALYSIS AND PERSONALIZED JOB RECOMMENDATIONS

ABSTRACT:

The goal of this thesis was to design and develop an AI-powered web application that enables the creation, analysis, and enhancement of resumes, as well as personalized job recommendations. The paper begins with an analysis of the problems faced by job applicants, including a lack of knowledge in creating a quality resume, information

overload when searching for jobs, and the limited availability of professional career counseling services. Existing digital solutions were also analyzed, and their limitations were identified, particularly regarding fragmentation and a lack of personalization. Based on the conducted analysis, the system's functional and non-functional requirements were defined, and an application architecture was designed based on the MERN technology stack. The developed system includes modules for user management, resume creation, resume analysis using AI technologies, and job recommendation through the integration of external API services. The value of the work lies in the application of natural language processing AI models, which enable semantic analysis of CV content, generation of recommendations for improvement, and matching user profiles with relevant job positions. The developed solution represents a functional platform that contributes to improving the recruitment process and the quality of CV documents.

Key words: *Artificial intelligence; Web application; CV analysis; Personalized job recommendation; Natural language processing*

POPIS SLIKA

Slika 3.1.	Korisnički interfejs za prijavu i registraciju	12
Slika 3.2.	Dijagram toka - modul za analizu CV-a	15
Slika 3.3.	Dijagram toka - integracija AI modula i API-ja	17
Slika 3.4.	Tehnološki stek dijagram	19
Slika 3.5.	Dijagram slučajeva korištenja iz perspektive korisnika	22
Slika 4.1.	Klasni dijagram	31
Slika 4.2.	Sekvencijalni dijagram	32
Slika 4.3.	ER dijagram	33
Slika 5.1.	Korisnički interfejs aplikacije	34
Slika 5.2.	Slojevita arhitektura backend sistema	35
Slika 5.3.	Preuzimanje kreiranog PDF-a	42
Slika 5.4.	Neuspješna registracija	44
Slika 5.5.	Prijava na sistem	45
Slika 5.6.	Zaboravljena lozinka	46
Slika 5.7.	Početna stranica	47
Slika 5.8.	Učitavanje PDF CV dokumenta	48
Slika 5.9.	Rezultati AI analize CV-a (preporuka poboljšanja)	49
Slika 5.10.	Generisanje sadržaja CV-a	50
Slika 5.11.	Rezultati AI analize CV-a (preporuka poslova)	51

POPIS TABELA

Tabela 2.1.	Pregled postojećih digitalnih rješenja za izradu i analizu CV-a te pretragu poslova	7
Tabela 3.1.	Funkcionalni zahtjevi – Upravljanje korisnicima	12
Tabela 3.2.	Funkcionalni zahtjevi – Modul za izradu CV-a	13
Tabela 3.3.	Funkcionalni zahtjevi – Modul za analizu CV-a	15
Tabela 3.4.	Funkcionalni zahtjevi – Modul za preporuku poslova	16
Tabela 3.5.	Nefunkcionalni zahtjevi sistema	18
Tabela 3.6.	Dijagram slučajeva korištenja: Registracija korisnika	23
Tabela 3.7.	Dijagram slučajeva korištenja: Prijava korisnika	24
Tabela 3.8.	Dijagram slučajeva korištenja: Učitavanje PDF CV-a	24
Tabela 3.9.	Dijagram slučajeva korištenja: AI analiza CV-a	25
Tabela 3.10.	Dijagram slučajeva korištenja: Pretraga poslova	25
Tabela 3.11.	Dijagram slučajeva korištenja: Generisanje sadržaja CV-a	26
Tabela 3.12.	Dijagram slučajeva korištenja: Preuzimanje CV-a kao PDF	26
Tabela 4.1.	Pregled korištenih tehnologija i slojeva sistema	28

POPIS KÔDA

Kôd 3.1. Prikaz ličnih podataka korisnika	13
Kôd 3.2. Konfiguracija frontend zavisnosti	20
Kôd 3.3. Konfiguracija backend zavisnosti	21
Kôd 4.1. User model	28
Kôd 4.2. CV model	29
Kôd 4.3. Job model	29
Kôd 5.1. Middleware za autorizaciju	36
Kôd 5.2. Autentifikacijske rute	36
Kôd 5.3. Logika pretrage poslova	38
Kôd 5.4. Definicija ruta	38
Kôd 5.5. Axios interceptor za autentifikaciju	39
Kôd 5.6. Auto-save logika	39
Kôd 5.7. Generisanje AI sadržaja	40
Kôd 5.8. Preuzimanje PDF dokumenta	41
Kôd 5.9. Heširanje lozinke	43

POPIS SKRAĆENICA

AI	Artificial Intelligence (Umjetna inteligencija)
API	Application Programming Interface (Programski interfejs)
ATS	Applicant Tracking Systems (Sistemi za praćenje kandidata)
CSS	Cascading Style Sheets (Stilovi u kaskadnom obliku)
CV	Curriculum Vitae (Biografija)
ER	Entity-Relationship (Entitet–veza)
HTML	HyperText Markup Language (Jezik za označavanje hiperteksta)
HTTP	HyperText Transfer Protocol (Protokol za prijenos hiperteksta)
JS	JavaScript
JSON	JavaScript Object Notation (Notacija objekata u JavaScriptu)
JWT	JSON Web Token (JSON mrežni token)
LLM	Large Language Models (Veliki jezički modeli)
MERN	MongoDB, Express.js, React, Node.js (Tehnološki MERN stek)
MVC	Model-View-Controller (Model–Prikaz–Kontroler)
NLP	Natural Language Processing (Obrada prirodnog jezika)
ODM	Object Data Modeling (Modeliranje objekata podataka)
PDF	Portable Document Format (Prijenosni format dokumenata)
REST	Representational State Transfer (Prijenos stanja resursa)
SDK	Software Development Kit (Komplet za razvoj softvera)
SPA	Single Page Application (Jednostranična aplikacija)
UML	Unified Modelling Language (Unificirani jezik modeliranja)
URL	Uniform Resource Locator (Uniformni lokator resursa)

SADRŽAJ

1. UVOD	1
2. OPIS PROBLEMA I PREGLED POSTOJEĆIH RJEŠENJA	4
2.1. Problemi u procesu zapošljavanja	4
2.1.1. Izazovi u kreiranju CV-a	5
2.1.2. Preopterećenost informacijama prilikom traženja posla	5
2.1.3. Nedostupnost usluga karijernog savjetovanja	6
2.2. Digitalne platforme za zapošljavanje	6
2.3. Uloga vještačke inteligencije pri zapošljavanju	8
3. ANALIZA SISTEMA I ZAHTJEVI	10
3.1. Analiza korisničkih potreba	10
3.2. Funkcionalni zahtjevi sistema	11
3.2.1. Upravljanje korisnicima	11
3.2.2. Modul za izradu CV-a	12
3.2.3. Modul za analizu CV-a	14
3.2.4. Modul za preporuku poslova	16
3.3. Nefunkcionalni zahtjevi	18
3.4. Tehnološki stek	18
3.4.1. Implementacione biblioteke i zavisnosti sistema	19
3.4.2. Frontend zavisnosti	20
3.4.3. Backend zavisnosti	21
3.5. Dijagram slučajeva korištenja sistema	22
3.5.1. Opis slučajeva korištenja	23
4. PROJEKTOVANJE WEB APLIKACIJE	27
4.1. Arhitektura sistema	27
4.2. Korištena tehnologija	28
4.3. Model podataka i dijagrami	28
4.3.1. Strukturalni UML dijagrami	30
4.3.2. Klasni dijagram	30
4.3.3. Bihevijoralni UML dijagrami	31
4.3.4. Sekvencijalni dijagram	32
4.3.5. ER dijagram baze podataka	32
5. IMPLEMENTACIJA WEB APLIKACIJE	34
5.1. Korištene tehnologije	34
5.1.1. Frontend tehnologije	34
5.1.2. Backend tehnologije	34
5.2. Implementacija backend dijela	35
5.2.1. Autentifikacija i autorizacija	36
5.2.2. Integracija pretrage poslova	37
5.3. Implementacija frontend dijela	38
5.3.1. Rutiranje i zaštita stranica	38
5.4. Komunikacija sa backend servisima	39
5.4.1. Automatsko čuvanje podataka	39

5.4.2.	Generisanje sadržaja pomoću AI	40
5.4.3.	Generisanje i preuzimanje PDF dokumenta	41
5.4.4.	Sigurnosni aspekti sistema	43
5.5.	Analiza rada platforme	43
6.	ZAKLJUČAK	52
7.	LITERATURA	54

1. UVOD

U savremenom dobu, obilježenom ubrzanim razvojem informacionih tehnologija, digitalnom transformacijom poslovnih procesa i globalnim ekonomskim promjenama, tržište rada prolazi kroz duboku strukturnu transformaciju koja značajno utiče na način zapošljavanja, profesionalnog razvoja i karijernog usmjeravanja pojedinaca. Tradicionalni modeli zapošljavanja, zasnovani na klasičnim metodama selekcije kandidata i manuelnoj obradi prijava, postepeno ustupaju mjesto automatizovanim sistemima, digitalnim platformama i inteligentnim alatima za analizu podataka. U takvom dinamičnom i konkurentnom okruženju, traženje zaposlenja postaje sve složeniji proces, obilježen intenzivnom konkurencijom, potrebom za stalnim unapređenjem vještina i prilagođavanjem zahtjevima tržišta rada.

U središtu tog procesa nalazi se biografija (eng. *Curriculum Vitae* – CV), koja predstavlja osnovni i često presudan element u selekciji kandidata. CV je u većini slučajeva prvi kontakt između kandidata i poslodavca, te funkcioniše kao primarni filter u procesu zapošljavanja, naročito u okruženju gdje se sve češće koriste automatizovani sistemi za selekciju prijava (eng. *Applicant Tracking Systems* - ATS). Uprkos njegovoj ključnoj ulozi, veliki broj tražilaca zaposlenja nema dovoljno znanja, iskustva niti stručne podrške za izradu profesionalnog, strukturiranog i tržišno usklađenog CV-a koji bi na adekvatan način predstavio njihove kompetencije, iskustvo i potencijal.

Dodatni izazov predstavlja način pretrage i pronalaska relevantnih oglasa za posao. Razvojem online platformi za zapošljavanje značajno je povećana dostupnost informacija i broja oglasa, ali je istovremeno došlo i do fragmentacije izvora podataka, jer se oglasi objavljuju na velikom broju različitih platformi, poput profesionalnih mreža, specijalizovanih portala za zapošljavanje i web stranica kompanija. Ovakva fragmentacija zahtijeva značajan vremenski i kognitivni napor korisnika, dok preopterećenost informacijama dodatno otežava identifikaciju relevantnih radnih pozicija. Kandidati su često suočeni s velikim brojem oglasa koji ne odgovaraju njihovim kvalifikacijama, dok istovremeno propuštaju prilike koje bi im realno odgovarale zbog neusklađenosti terminologije, opisa vještina i zahtjeva poslodavaca.

Poseban problem predstavlja nesklad između načina na koji kandidati opisuju svoje kompetencije i načina na koji poslodavci formulišu zahtjeve u oglasima za posao. Ovaj semantički jaz dovodi do situacija u kojima odgovarajući kandidati ne bivaju prepoznati kao potencijalni izbori, iako objektivno posjeduju tražene vještine i znanja. Tradicionalni sistemi pretrage, zasnovani prvenstveno na ključnim riječima, dodatno produbljuju ovaj problem, jer ne razumiju kontekst, značenje i povezanost pojmova, već se oslanjaju isključivo na površinsko podudaranje termina.

U takvom okruženju, profesionalne usluge karijernog savjetovanja, izrade CV-a i analize profesionalnog profila postaju sve značajnije, ali su u praksi često finansijski nedostupne širem krugu korisnika. Time se stvara dodatna neravnoteža između kandidata koji imaju pristup stručnim resursima i onih koji su prepušteni samostalnom snalaženju u kompleksnom sistemu digitalnog tržišta rada.

Pojava i rapidan razvoj tehnologija zasnovanih na umjetnoj inteligenciji (eng. *Artificial Intelligence - AI*) otvaraju nove mogućnosti za transformaciju procesa zapošljavanja i karijernog usmjeravanja. Savremeni AI sistemi, posebno oni zasnovani na naprednim modelima obrade prirodnog jezika (eng. *Large Language Models – LLM*), omogućavaju razumijevanje konteksta, semantičku analizu teksta, identifikaciju vještina, analizu profesionalnih profila i generisanje personalizovanih preporuka. Umjetna inteligencija u ovom kontekstu ne funkcioniše samo kao alat za automatizaciju, već kao inteligentni savjetodavni sistem koji može objektivno analizirati podatke, prepoznati obrasce i pružiti korisnicima konkretne, primjenjive smjernice za unapređenje profesionalnog profila i karijernog razvoja.

Ipak, iako postoje brojna digitalna rješenja koja nude pojedinačne funkcionalnosti, poput izrade CV-a, pretrage poslova ili analize dokumenata, većina postojećih platformi ostaje fragmentirana i funkcionalno ograničena. Korisnici su primorani koristiti više različitih alata i servisa, što dovodi do neefikasnosti, složenog upravljanja podacima, gubitka kontinuiteta i nedostatka integrisanog korisničkog iskustva. Također, veliki broj platformi ne nudi stvarnu personalizaciju, već se oslanja na generičke šablone, osnovne filtre i površinsku analizu podataka.

S ciljem prevazilaženja navedenih izazova, u okviru ovog završnog rada razvijena je web aplikacija sa integrisanom podrškom umjetne inteligencije, čiji je cilj demokratizacija pristupa profesionalnom karijernom savjetovanju i digitalnim alatima za zapošljavanje. Razvijeno rješenje objedinjuje proces kreiranja profesionalnog CV-a, njegovu inteligentnu analizu i personalizovanu preporuku poslova u okviru jedinstvene, centralizovane platforme. Integracijom savremenih web tehnologija i naprednih AI servisa, sistem omogućava automatizovanu analizu sadržaja CV-a, prepoznavanje vještina, generisanje preporuka za unapređenje kvaliteta dokumenta, te semantičko povezivanje profesionalnog profila korisnika s relevantnim radnim pozicijama.

Na ovaj način, aplikacija ne predstavlja samo tehničko rješenje, već funkcioniše kao inteligentni digitalni karijerni asistent, koji korisnicima omogućava aktivnu podršku u procesu profesionalnog razvoja, unapređenja zapošljavanja i efikasnijeg pozicioniranja na savremenom tržištu rada. Automatizacijom ključnih faza procesa zapošljavanja, smanjenjem preopterećenosti informacijama i uvođenjem personalizovanog pristupa, razvijeni sistem doprinosi povećanju kvaliteta prijave za posao i smanjenju prepreka s kojima se suočavaju osobe koje traže posao.

U drugom poglavlju ovog rada analiziraju se problemi tradicionalnih i savremenih digitalnih rješenja u procesu zapošljavanja, uz pregled dostupnih rješenja i njihovih prednosti i nedostataka.

Zatim, u narednom dijelu definišu se funkcionalni i nefunkcionalni zahtjevi sistema, vrši analiza korisničkih potreba, te se opisuje arhitektura sistema i korištene tehnologije.

U četvrtom dijelu prikazan je opis projektovanja web aplikacije, uključujući dizajn arhitekture sistema, model podataka i dijagrame koji olakšavaju razumijevanje funkcionalnosti aplikacije.

Nakon toga detaljno se opisuje implementacija web aplikacije, uključujući frontend

i backend tehnologije, integraciju AI servisa, generisanje sadržaja i PDF dokumenata, te sigurnosne aspekte sistema.

U završnom dijelu rada data su zaključna razmatranja o razvijenom rješenju, uz prijedloge za njegovo unapređenje i moguće pravce daljeg razvoja.

2. OPIS PROBLEMA I PREGLED POSTOJEĆIH RJEŠENJA

Tržište zapošljavanja i digitalnih platformi za zapošljavanje bilježi ubrzan rast usljed globalne digitalizacije i sve veće primjene informacionih tehnologija u procesima selekcije kandidata. Online platforme za zapošljavanje, profesionalno umrežavanje i upravljanje karijerom postale su ključni posrednici između poslodavaca i kandidata, dok se tradicionalni načini prijave za posao sve više zamjenjuju automatizovanim i algoritamski vođenim sistemima. Razvoj sistema za praćenje kandidata (ATS), digitalnih baza oglasa i alata za analizu podataka značajno je promijenio način na koji se procjenjuju kvalifikacije i kompetencije, stavljajući dodatni naglasak na kvalitet i strukturu biografije. Istovremeno, ubrzan razvoj tehnologija zasnovanih na umjetnoj inteligenciji otvorio je nove mogućnosti za unapređenje procesa zapošljavanja, ali je također ukazao na postojeće nedostatke u pristupačnosti i efikasnosti alata namijenjenih osobama koje traže posao.

2.1. Problemi u procesu zapošljavanja

Savremeno tržište rada karakteriše visoka konkurencija, globalna dostupnost radnih pozicija i sve veća primjena digitalnih sistema za selekciju kandidata [1]. U takvom okruženju, osobe koje traže posao suočavaju se s nizom izazova koji direktno utiču na uspjeh njihovih prijavi za posao. Jedan od ključnih faktora u ovom procesu jeste kvalitet i struktura biografije (CV), kao i sposobnost kandidata da pronađe relevantne oglase za posao koji odgovaraju njegovim kvalifikacijama, kompetencijama i profesionalnim ciljevima. Uprkos velikoj dostupnosti online alata i platformi, ovi izazovi i dalje ostaju izraženi, naročito kod mladih osoba, početnika u karijeri i osoba koje mijenjaju profesionalni pravac.

Tradicionalni proces zapošljavanja opterećen je brojnim neefikasnostima koje dodatno otežavaju poziciju kandidata. Jedan od čestih problema predstavlja tzv. „sindrom prazne stranice“, gdje kandidati ne znaju šta tačno napisati u CV, kako strukturirati sadržaj, koje informacije su relevantne i na koji način koristiti ključne riječi koje su prepoznatljive digitalnim sistemima za selekciju (ATS) [2]. Izrada kvalitetnog CV-a zahtijeva specifična znanja i vještine koje mnogi stručnjaci iz drugih oblasti ne posjeduju, jer nisu dio njihove formalne edukacije niti profesionalne prakse. Posebno su pogođeni diplomanti i mladi profesionalci, koji često imaju poteškoće da akademska postignuća, projekte i stečene kompetencije predstavljaju na način koji je razumljiv i relevantan poslodavcima i tržištu rada.

Dodatni problem predstavlja nedostatak povratne informacije u procesu zapošljavanja. Kandidati nerijetko apliciraju na veliki broj radnih pozicija bez ikakvog odgovora ili objašnjenja razloga odbijanja, što onemogućava učenje iz grešaka i unapređenje prijavi. Ovakva praksa dovodi do psihološkog zamora, gubitka motivacije i osjećaja profesionalne nesigurnosti, posebno kod osoba na početku karijere. Proces traženja posla postaje dugotrajan, neefikasan i demotivirajući, pri čemu kandidati često nemaju jasne smjernice kako unaprijediti svoj profesionalni profil.

Istovremeno, fragmentiranost oglasa za posao na velikom broju digitalnih platformi dodatno komplikuje proces zapošljavanja. Kandidati su prisiljeni pretraživati različite

sisteme, portale i baze podataka, često koristeći generičke ključne riječi, što rezultira velikim brojem nerelevantnih rezultata. Postoji i čest nesklad između načina na koji kandidati opisuju svoje vještine i načina na koji su zahtjevi za posao formulisani u oglasima, što dovodi do propuštanja odgovarajućih prilika čak i kada realno postoji podudarnost između profila kandidata i zahtjeva poslodavca.

Sve navedeno ukazuje na potrebu za savremenim, inteligentnim i integrisanim digitalnim rješenjima koja bi omogućila korisnicima strukturisanu podršku u procesu zapošljavanja, od kreiranja kvalitetnog CV-a, preko njegove analize i unapređenja, do pronalaska relevantnih radnih pozicija. Bez sistemskog i tehnološki potpomognutog pristupa, proces zapošljavanja ostaje fragmentiran, neefikasan i izrazito opterećujući za pojedinca, što dodatno naglašava značaj razvoja naprednih platformi zasnovanih na vještačkoj inteligenciji i automatizovanoj analizi podataka.

2.1.1. Izazovi u kreiranju CV-a

Izrada profesionalnog CV-a predstavlja značajan problem za veliki broj kandidata, naročito za osobe koje prvi put traže posao. Mnogi korisnici nisu upoznati sa savremenim standardima pisanja CV-a, pravilnim strukturiranjem sadržaja, niti načinima na koje se radno iskustvo i postignuća trebaju predstaviti potencijalnim poslodavcima. Česti problemi uključuju neadekvatnu dužinu CV-a, lošu organizaciju sekcija, nedostatak jasno definisanih postignuća, kao i izostanak kvantifikacije rezultata rada. Dodatno, sadržaj CV-a često nije prilagođen konkretnoj radnoj poziciji, što dovodi do nesklada između zahtjeva poslodavca i informacija koje kandidat prezentuje.

Poseban izazov predstavlja činjenica da se u savremenim procesima zapošljavanja sve češće koriste automatizovani sistemi za praćenje kandidata (ATS), koji filtriraju prijave na osnovu unaprijed definisanih kriterija [3]. CV dokumenti koji nisu pravilno strukturirani ili ne sadrže odgovarajuće ključne riječi često bivaju automatski odbačeni, bez obzira na stvarne kvalifikacije kandidata. Time se dodatno povećava potreba za alatima koji mogu pomoći korisnicima u izradi CV-a prilagođenog savremenim tehničkim i profesionalnim standardima.

2.1.2. Preopterećenost informacijama prilikom traženja posla

Drugi značajan problem s kojim se suočavaju osobe koje traže posao jeste preopterećenost informacijama. Tržište rada je podijeljeno između velikog broja platformi, portala i društvenih mreža, što od kandidata zahtijeva kontinuirano pretraživanje različitih izvora. Kao posljedica toga, korisnici često provode puno vremena pregledajući oglase koji nisu relevantni za njihov profil, dok istovremeno propuštaju prilike koje bi mogle odgovarati njihovim vještinama i iskustvu.

Većina postojećih platformi oslanja se na jednostavne mehanizme pretrage zasnovane na ključnim riječima, što ne omogućava dublje razumijevanje značenja i konteksta oglasa za posao niti profesionalnog profila kandidata. Ovakav pristup dovodi do ograničenih i često nepreciznih rezultata pretrage, čime se smanjuje efikasnost procesa zapošljavanja i

povećava frustracija korisnika.

2.1.3. Nedostupnost usluga karijernog savjetovanja

Usluge karijernog savjetovanja, izrade i pregleda CV-a, kao i pripreme za zapošljavanje, predstavljaju dodatni izazov zbog svoje ograničene dostupnosti. Iako ove usluge mogu značajno unaprijediti kvalitet prijave za posao, one su u većini slučajeva finansijski nedostupne studentima, nezaposlenim osobama i osobama u ranim fazama karijere. Ovaj problem je posebno izražen u zemljama u razvoju, gdje ne postoji razvijena infrastruktura za sistemsku podršku tražiocima posla. Zbog toga se javlja potreba za pristupačnim, automatizovanim i inteligentnim rješenjima koja mogu zamijeniti ili dopuniti tradicionalne oblike karijernog savjetovanja.

2.2. Digitalne platforme za zapošljavanje

Na tržištu trenutno postoji više različitih tipova digitalnih rješenja koja pokušavaju odgovoriti na navedene probleme. U zavisnosti od funkcionalnosti koje nude, postojeća rješenja mogu se klasificirati na: aplikacije za izradu CV-a, agregatore poslova te alate zasnovane na vještačkoj inteligenciji za analizu CV-a. Aplikacije za izradu, poput Canva Resume, Resume.io i Zety, spadaju među najčešće korištene alate, posebno među studentima i osobama na početku karijere. Njihova glavna prednost ogleda se u jednostavnosti korištenja, dostupnosti unaprijed definisanih šablona i vizuelno privlačnom dizajnu koji omogućava brzo kreiranje profesionalnih dokumenata.

Međutim, iako ovakvi alati olakšavaju tehnički aspekt izrade CV-a, njihov fokus je primarno usmjeren na estetski izgled, dok je analiza samog sadržaja u velikoj mjeri zanemarena. Većina ovih aplikacija ne nudi inteligentnu procjenu kvaliteta unesenih informacija, ne daje preporuke za prilagođavanje CV-a određenoj poziciji, niti uzima u obzir specifične zahtjeve tržišta rada. Kao rezultat toga, korisnici često dobiju vizuelno atraktivan, ali sadržajno nedovoljno optimizovan CV.

Kako bi se omogućilo jasnije poređenje prednosti i nedostataka postojećih tipova digitalnih rješenja, u Tabeli 2.1. prikazan je njihov pregled.

Tabela 2.1. Pregled postojećih digitalnih rješenja za izradu i analizu CV-a te pretragu poslova

Tip rješenja	Primjeri	Prednosti	Nedostaci
Aplikacije za izradu CV-a	Canva ¹ , Zety ²	Vizuelno privlačni šabloni; brzo kreiranje CV-a; jednostavno korištenje	Fokus na dizajn dokumenta bez napredne analize sadržaja i personalizovanih preporuka
Agregatori poslova	LinkedIn ³ , Indeed ⁴	Velika baza oglasa za posao; široka dostupnost; osnovni filteri pretrage	Pretraga zasnovana uglavnom na ključnim riječima; ograničena personalizacija preporuka
AI alati za analizu CV-a	Jobscan ⁵ , Worded ⁶	Resume Automatizovana analiza CV-a; povratne informacije; preporuke za poboljšanje	Često dostupni samo kroz pretplatu; bez integracije s platformama za pretragu poslova
Integrirana AI aplikacija za CV analizu i preporuku poslova	ResumeVision	Integracija više funkcionalnosti: kreiranje CV-a; AI analiza postojećeg CV-a; automatske preporuke za poboljšanje; preporuka relevantnih oglasa za posao	Prototipska implementacija sa ograničenim brojem podržanih izvora oglasa za posao

¹ <https://www.canva.com>

² <https://zety.com>

³ <https://www.linkedin.com>

⁴ <https://www.indeed.com>

⁵ <https://www.jobscan.co>

⁶ <https://resumeworded.com>

ResumeVision aplikacija omogućava korisnicima da brzo kreiraju CV koristeći unaprijed definisane šablone i vizuelno privlačne dizajne. Iako su ovakvi alati korisni za osnovnu izradu dokumenata, oni uglavnom ne nude inteligentnu analizu sadržaja niti personalizovane preporuke. S druge strane, agregatori poslova okupljaju veliki broj oglasa na jednom mjestu i omogućavaju osnovno filtriranje, ali se najčešće oslanjaju na pretragu ključnih riječi, bez dubljeg razumijevanja profesionalnog profila korisnika. AI alati za

analizu CV-a pružaju automatizovane povratne informacije, ali su često ograničeni na jednu funkcionalnost i dostupni isključivo kroz pretplatne modele.

2.3. Uloga vještačke inteligencije pri zapošljavanju

Vještačka inteligencija sve intenzivnije transformiše procese zapošljavanja, prelazeći put od statičkih digitalnih alata ka inteligentnim sistemima koji aktivno učestvuju u analizi podataka, donošenju odluka i pružanju podrške korisnicima. Savremeni AI modeli djeluju kao digitalni asistenti sposobni za razumijevanje konteksta, obradu složenih informacija i generisanje smislenih preporuka, čime se značajno unapređuju efikasnost i kvalitet procesa selekcije kandidata i profesionalnog usmjeravanja.

U savremenom zapošljavanju, AI se već široko primjenjuje u automatizovanoj selekciji kandidata kroz ATS sisteme, koji analiziraju sadržaj biografija i porede ga sa zahtjevima radnih pozicija. Iako ovi sistemi povećavaju efikasnost selekcije, kandidati često ostaju u nepovoljnom položaju zbog nedostatka uvida u kriterije evaluacije i načine prilagođavanja svojih CV dokumenata. Koncept razvijen u ovom radu polazi od ideje da se slične AI tehnologije ne koriste isključivo na strani poslodavaca, već i kao alat podrške kandidatima, čime se uspostavlja ravnoteža u digitalnom procesu zapošljavanja.

Pored selekcije, značajna uloga AI ogleda se u inteligentnom generisanju sadržaja, gdje modeli vještačke inteligencije omogućavaju kreiranje profesionalnih sažetaka, opisa radnih zadataka i strukturiranih formulacija kompetencija, uz očuvanje formalnog stila i jezičke preciznosti. Time se korisnicima omogućava kvalitetno i tržišno relevantno predstavljanje vlastitih kvalifikacija, nezavisno od njihovih vještina poslovne komunikacije.

Posebna vrijednost AI sistema ogleda se u semantičkom razumijevanju sadržaja, koje omogućava povezivanje različitih naziva pozicija, vještina i profesionalnih profila na osnovu značenja, a ne isključivo ključnih riječi. Ovakav pristup omogućava preciznije i relevantnije preporuke poslova, smanjuje broj propuštenih prilika i povećava vjerovatnoću pronalaska odgovarajućeg zaposlenja.

Razvijena web aplikacija se izdvaja integrisanim pristupom koji objedinjuje sve ključne funkcionalnosti procesa zapošljavanja u okviru jedinstvene platforme, od kreiranja profesionalnog CV-a, preko njegove inteligentne analize, do personalizovane preporuke poslova. Centralnu ulogu u diferencijaciji sistema ima integracija Google Gemini AI servisa, koji omogućava naprednu obradu prirodnog jezika, prepoznavanje ključnih kompetencija i generisanje smislenih preporuka za unapređenje sadržaja CV-a, čime se prevazilaze ograničenja klasičnih alata zasnovanih na statičkim pravilima i prostom podudaranju pojmova.

Posebna prednost aplikacije ogleda se u podršci za bosanski jezik, čime je sistem direktno prilagođen lokalnom tržištu rada i potrebama korisnika u Bosni i Hercegovini. Time se povećava dostupnost, preciznost analize i praktična vrijednost rješenja za lokalne korisnike. Dodatno, aplikacija je osmišljena kao pristupačno, korisnički orijentisano rješenje bez složenih pretplatnih modela, čime savremeni alati za karijerni razvoj postaju dostupni širem krugu korisnika. Funkcionalnosti poput pregleda CV-a u realnom vremenu

i generisanja profesionalnog PDF dokumenta dodatno unapređuju korisničko iskustvo i omogućavaju efikasno kreiranje finalnog dokumenta spremnog za proces prijave na posao.

Na taj način, predloženo rješenje predstavlja sveobuhvatnu platformu koja uspješno kombinuje moderne web tehnologije i vještačku inteligenciju, nudeći funkcionalno, personalizovano i dostupno rješenje za savremene izazove tržišta rada.

3. ANALIZA SISTEMA I ZAHTJEVI

Izvršena je detaljna analiza funkcionalnih i nefunkcionalnih zahtjeva razvijene web aplikacije, kao i pregled korištenih tehnologija. Cilj analize bio je jasno definisati ponašanje sistema, njegove ključne funkcionalnosti i ograničenja, te osigurati da implementirano rješenje odgovara potrebama krajnjih korisnika i savremenim standardima web razvoja. Poseban fokus stavljen je na modularnu arhitekturu sistema, skalabilnost rješenja i integraciju servisa zasnovanih na vještačkoj inteligenciji.

3.1. Analiza korisničkih potreba

Analiza korisničkih potreba predstavlja ključni korak u procesu projektovanja sistema, jer omogućava razumijevanje stvarnih problema, očekivanja i ciljeva krajnjih korisnika. Efikasnost i prihvaćenost sistema u velikoj mjeri zavise od njegove usklađenosti sa stvarnim potrebama korisnika, zbog čega je neophodno identifikovati osnovne grupe korisnika i definisati njihove specifične zahtjeve. U okviru rada identifikovane su dvije dominantne korisničke grupe: osobe koje traže posao i osobe koje mijenjaju profesiju. U prvu grupu spadaju: studenti, nedavni diplomanti, nezaposlene osobe i profesionalci u ranoj fazi karijere. Ovu grupu karakteriše potreba za brzim, jednostavnim i pouzdanim alatima koji omogućavaju izradu profesionalnog CV-a bez tehničkih i dizajnerskih prepreka. Ovi korisnici često nemaju znanje o pravilnom formatiranju dokumenata, strukturi CV-a i profesionalnim standardima prezentacije sadržaja, zbog čega im je potreban sistem koji automatizuje ovaj proces i vodi ih kroz izradu kvalitetnog dokumenta.

Pored same izrade CV-a, izražena je potreba za objektivnom procjenom kvaliteta postojećih biografija. Korisnici često nemaju jasnu povratnu informaciju o tome da li je njihov CV konkurentan na tržištu rada, koji su njegovi nedostaci i na koji način ga mogu unaprijediti. Nedostatak povratnih informacija dovodi do nesigurnosti, ponovljenih neuspješnih prijava i smanjene motivacije. Zbog toga postoji potreba za inteligentnim sistemom koji omogućava automatsku analizu CV-a, prepoznavanje slabih tačaka i generisanje konkretnih preporuka za poboljšanje.

Treći ključni aspekt potreba primarnih korisnika odnosi se na pronalazak relevantnih poslova. Klasične platforme za zapošljavanje najčešće se oslanjaju na pretragu po nazivima pozicija i ključnim riječima, što često rezultira nepreciznim preporukama i propuštanjem kvalitetnih prilika [2]. Korisnicima je potreban sistem koji ne povezuje radne pozicije isključivo prema nazivu posla, već prema stvarnom skupu vještina, znanja i kompetencija koje posjeduju, čime se omogućava preciznije i personalizovanije preporučivanje oglasa za posao.

Sekundarnu grupu korisnika čine osobe koje mijenjaju profesionalni pravac i prelaze u novu industriju ili oblast rada. Ova grupa se suočava sa specifičnim izazovima, jer njihovo prethodno iskustvo često nije direktno povezano sa novom profesionalnom orijentacijom. Njihova osnovna potreba jeste stručna podrška u reinterpetaciji postojećeg iskustva i identifikaciji prenosivih vještina koje mogu biti relevantne u novom kontekstu. Takvi

korisnici često ne znaju kako da svoje prethodne pozicije, znanja i kompetencije predstave na način koji je razumljiv i prihvatljiv poslodavcima u drugoj industriji.

Ovoj grupi korisnika potreban je sistem koji omogućava inteligentnu analizu profesionalne biografije, prepoznavanje univerzalnih vještina (npr. komunikacija, organizacija, timski rad, analitičko razmišljanje, digitalne kompetencije) i njihovo adekvatno mapiranje na zahtjeve novih radnih pozicija. Time se olakšava tranzicija između karijera i prevazilazi barijera ulaska u nove profesionalne oblasti.

Na osnovu identifikovanih korisničkih potreba, razvijeni sistem je koncipiran kao integrisana platforma koja objedinjuje izradu CV-a, njegovu inteligentnu analizu i personalizovanu preporuku poslova. Takav pristup omogućava podršku različitim korisničkim profilima, pružajući ne samo tehničke alate, već i funkcionalnosti koje imaju savjetodavnu i razvojnu ulogu u procesu profesionalnog usmjeravanja. Sistem je time usmjeren ka stvaranju rješenja koje ne odgovara samo na tehničke zahtjeve korisnika, već i na njihove stvarne profesionalne potrebe i izazove na savremenom tržištu rada [1].

3.2. Funkcionalni zahtjevi sistema

Funkcionalni zahtjevi opisuju ponašanje sistema i funkcionalnosti koje aplikacija mora omogućiti korisnicima. Na osnovu analize problema i ciljeva sistema, funkcionalnosti su grupisane u četiri osnovna modula: upravljanje korisnicima, modul za izradu CV-a, modul za analizu CV-a i modul za preporuku poslova.

3.2.1. Upravljanje korisnicima

Modul za upravljanje korisnicima predstavlja osnovu sistema i zadužen je za autentifikaciju, autorizaciju i sigurnost korisničkih podataka. Kroz ovaj modul omogućene su sljedeće funkcije:

1. Registracija – korisnici mogu kreirati novi nalog koristeći email adresu i lozinku. Lozinke se sigurno pohranjuju koristeći algoritam za hashiranje, čime se osigurava zaštita osjetljivih podataka u slučaju neovlaštenog pristupa bazi podataka.
2. Prijava – korisnici se mogu prijaviti koristeći svoje pristupne podatke. Nakon uspješne autentifikacije, sistem generiše JWT (eng. *JSON Web Token*) koji se koristi za upravljanje sesijama i kontrolu pristupa zaštićenim resursima unutar aplikacije. JWT token omogućava sigurnu i skalabilnu autentifikaciju bez potrebe za stalnim provjerama baze podataka.
3. Resetovanje zaboravljene lozinke – sistem omogućava korisnicima da zatraže reset lozinke putem email adrese. Nakon verifikacije identiteta, korisnik može sigurno postaviti novu lozinku. Ova funkcionalnost dodatno poboljšava korisničko iskustvo i sigurnost.
4. Upravljanje sesijama i autorizacija – modul prati korisničke sesije i osigurava da samo ovlašteni korisnici mogu pristupiti određenim dijelovima aplikacije. Ovo


uključuje provjeru JWT tokena pri svakom zahtjevu prema zaštićenim endpointima backend servera (Node.js + Express).

Sažeti opis funkcionalnosti prikazan je u Tabeli 3.1.

Tabela 3.1. Funkcionalni zahtjevi – Upravljanje korisnicima

Oznaka	Opis zahtjeva
FR-1	Registracija korisnika putem email adrese i lozinke
FR-2	Prijava korisnika uz JWT autentifikaciju
FR-3	Funkcionalnost resetovanja lozinke
FR-4	Upravljanje sesijom i odjava korisnika

Na Slici 3.1 prikazan je interfejs za registraciju i prijavu korisnika.



Slika 3.1. Korisnički interfejs za prijavu i registraciju

Kombinacija ovih funkcionalnosti i korištenih tehnologija (Node.js, Express, MongoDB, Mongoose, JWT, bcryptjs) omogućava sigurno, pouzdano i skalabilno upravljanje korisnicima, čime se postavljaju čvrste osnove za sve ostale module web aplikacije, uključujući kreiranje i analizu CV-a te personalizovane preporuke poslova.

3.2.2. Modul za izradu CV-a

Modul za izradu CV-a omogućava korisnicima kreiranje profesionalnog životopisa kroz intuitivan i interaktivan interfejs. Korisnik unosi lične podatke, radno iskustvo, obrazovanje i vještine, dok sistem u realnom vremenu prikazuje pregled finalnog dokumenta. Posebna vrijednost ovog modula ogleda se u integraciji AI servisa koji generišu profesionalni sažetak i opise radnih pozicija, čime se poboljšava kvalitet sadržaja CV-a.

Sistem implementira mehanizam automatskog spremanja podataka u redovnim vremenskim intervalima, čime se osigurava da se sve unesene informacije kontinuirano pohranjuju tokom rada korisnika u aplikaciji. Na taj način se smanjuje mogućnost gubitka podataka u slučaju prekida rada aplikacije, zatvaranja preglednika ili drugih tehničkih problema, te sve informacije koje korisnik unosi u formu automatski se prikazuju na predlošku CV-a bez potrebe za ponovnim učitavanjem stranice. Nakon završetka unosa i uređivanja informacija, korisnik ima mogućnost preuzeti generisani CV u PDF formatu, pri čemu se izgled dokumenta automatski prilagođava odabranom predlošku i zadržava strukturu prikazanu u aplikaciji. Funkcionalni zahtjevi koji definišu rad ovog modula prikazani su u Tabeli 3.2.

Tabela 3.2. Funkcionalni zahtjevi – Modul za izradu CV-a

Oznaka	Opis zahtjeva
FR-5	Unos ličnih podataka korisnika
FR-6	Upravljanje radnim iskustvom
FR-7	Upravljanje obrazovanjem
FR-8	Unos i uređivanje vještina
FR-9	Upload profilne fotografije
FR-10	AI generisanje profesionalnog sažetka
FR-11	AI generisanje opisa radnih pozicija
FR-12	Pregled CV-a u realnom vremenu
FR-13	Automatsko spremanje unosa
FR-14	Izvoz CV-a u PDF format

Kao što je prikazano u isječku kôda 3.1, podaci o korisniku se dohvaćaju iz objekta cvData, uključujući lične podatke, kontakt informacije i radno iskustvo. Lični podaci poput imena, email adrese, telefona i adrese prikazuju se direktnim referenciranjem odgovarajućih atributa objekta cvData.personal.

```
<div id="cv-preview-content" className="resume-container">
  {/ * LEFT SIDEBAR: Contact & Personal Info */}
  <aside className="sidebar">
    <div className="profile-container">
      {cvData.personal.photo && (
        <img src={cvData.personal.photo} className="profile-img"
          alt="Profile" />
      )}
    </div>

    <div className="sidebar-section">
      <h3 className="sidebar-title">Kontakt</h3>
      <div className="contact-info">
        <p>{cvData.personal.email}</p>
      </div>
    </div>
  </aside>
</div>
```

```

        <p>{cvData.personal.phone}</p>
        <p>{cvData.personal.address}</p>
    </div>
</div>
</aside>

{/* RIGHT MAIN CONTENT: Experience & Skills */}
<main className="main-content">
    <div className="header-block">
        <h1 className="header-name">{cvData.personal.fullName}
        || 'Vase Ime'</h1>
        <p className="header-title">{cvData.personal.profession}
        || 'Vasa Titula'</p>
    </div>

    {/* Dynamic mapping of experience array */}
    {cvData.experience.length > 0 && (
        <div className="main-section">
            <h2 className="main-title">Radno Iskustvo</h2>
            {cvData.experience.map((exp, index) => (
                <div key={index} className="exp-item">
                    <div className="flex justify-between font-bold">
                        <span>{exp.title}</span>
                        <span className="text-sm text-gray-500">{exp.startDate}
                        - {exp.endDate}</span>
                    </div>
                    <div className="italic text-gray-700">{exp.company}</div>
                    <p className="mt-1 text-sm">{exp.description}</p>
                </div>
            ))}
        </div>
    )}
</main>
</div>

```

Kôd 3.1. Prikaz ličnih podataka korisnika

Ukoliko korisnik nije unio određene informacije, sistem prikazuje podrazumijevane vrijednosti, čime se osigurava konzistentan izgled predloška.

3.2.3. Modul za analizu CV-a


Modul za analizu CV-a omogućava korisnicima upload postojećih CV dokumenata u PDF formatu. Sistem vrši ekstrakciju teksta iz dokumenta, nakon čega se sadržaj analizira pomoću vještačke inteligencije.

U Tabeli 3.3 prikazani su funkcionalni zahtjevi za analizu CV-a, koji definišu ključne funkcionalnosti sistema u okviru ovog modula.

Tabela 3.3. Funkcionalni zahtjevi – Modul za analizu CV-a

Oznaka	Opis zahtjeva
FR-15	Upload CV dokumenta u PDF formatu
FR-16	Ekstrakcija teksta iz PDF dokumenta
FR-17	AI analiza sadržaja i prepoznavanje vještina
FR-18	Generisanje prijedloga za poboljšanje CV-a
FR-19	Izračun kvalitativne ocjene CV-a (0–100)
FR-20	Prikaz strukturiranih rezultata analize

Na Slici 3.2 prikazan je detaljan dijagram toka koji ilustrira rad modula za analizu CV-a.



Slika 3.2. Dijagram toka - modul za analizu CV-a

Analiza uključuje prepoznavanje vještina, identifikaciju slabih tačaka, prijedloge za poboljšanje i izračun ukupne kvalitativne ocjene CV-a u rasponu od 0 do 100. Rezultati analize se odmah prikazuju korisniku u vizuelnom formatu.

3.2.4. Modul za preporuku poslova

Na osnovu vještina prepoznatih u CV-u, sistem automatski generiše personalizovane preporuke poslova korištenjem Jooble API servisa. Korisnicima se prikazuju relevantni oglasi sa osnovnim informacijama i direktnim linkovima za prijavu. Kako bi se poboljšale performanse sistema, rezultati pretrage se keširaju na ograničeno vrijeme. U Tabeli 3.4 prikazani su funkcionalni zahtjevi za preporuku poslova.

Tabela 3.4. Funkcionalni zahtjevi – Modul za preporuku poslova


Oznaka	Opis zahtjeva
FR-21	Generisanje personalizovanih preporuka poslova
FR-22	Prikaz osnovnih informacija o oglasima
FR-23	Direktni linkovi za prijavu na oglase
FR-24	Keširanje rezultata pretrage poslova

Na Slici 3.3 je prikazan sekvencijski dijagram toka koji ilustruje integraciju AI modula za analizu CV-a i modul za pretragu poslova putem API-ja. Prvi scenarij se odnosi na AI modul za analizu CV-a, gdje korisnik učitava svoj PDF CV, frontend šalje podatke backend-u, koji potom parsira dokument u tekst, šalje ga Google Gemini AI modelu za generisanje ocjene, izvlačenje vještina i prijedloga za poboljšanje. Rezultati se potom pohranjuju u bazu podataka i vraćaju korisniku, koji ih može pregledati u obliku ocjene i preporuka.

Drugi scenarij opisuje modul za integraciju poslova, gdje korisnik pristupa dashboard-u kako bi vidio preporučene poslove. Backend dohvaća vještine korisnika iz baze, provjerava cache i, ukoliko je potrebno, šalje zahtjev eksternom Jooble API-ju radi dohvaćanja relevantnih oglasa.

Dobiveni podaci se potom pohranjuju u cache i vraćaju frontend-u, koji ih prikazuje korisniku u obliku kartica sa detaljima poslova.

Dijagram sa Slike 3.3 jasno prikazuje protok podataka između korisnika, frontend-a, backend-a, baze podataka, eksternih AI i job API-ja, čime se vizualizuje cjelokupan proces obrade CV-a i preporuke poslova unutar aplikacije.



Slika 3.3. Dijagram toka - integracija AI modula i API-ja

Na osnovu toga se jasno vidi kako sistem funkcioniše kao cjelina, gdje svaka komponenta ima svoju ulogu u obradi podataka i generisanju rezultata.

3.3. Nefunkcionalni zahtjevi

Nefunkcionalni zahtjevi definišu kvalitet sistema u pogledu performansi, sigurnosti, pouzdanosti i upotrebljivosti. Ovi zahtjevi osiguravaju stabilan i siguran rad aplikacije u realnim uslovima korištenja.

Nefunkcionalni zahtjevi sistema prikazani su u Tabeli 3.5 gdje su definisane ključne karakteristike sistema u pogledu performansi, sigurnosti, upotrebljivosti i pouzdanosti.

Tabela 3.5. Nefunkcionalni zahtjevi sistema

Zahtjev	Kategorija	Specifikacija
Vrijeme učitavanja	Performanse	Manje od 3 sekunde
Vrijeme AI analize	Performanse	Manje od 30 sekundi
Hashiranje lozinki	Sigurnost	bcrypt (12 rundi)
Autentifikacija	Sigurnost	JWT tokeni (istek 1 sat)
Responzivni dizajn	Upotrebljivost	Podrška za mobilne i desktop uređaje
Dostupnost sistema	Pouzdanost	99% vremena
Retry mehanizam	Pouzdanost	3 pokušaja sa kašnjenjem

Fokus na performanse osigurava brzo i efikasno izvođenje operacija, dok sigurnosne mjere štite osjetljive podatke korisnika i održavaju integritet sistema. Upotrebljivost kroz responzivni dizajn omogućava jednostavno korištenje aplikacije na različitim uređajima, a pouzdanost, postignuta visokim nivoom dostupnosti i implementacijom mehanizama za ponovno pokušavanje, garantuje kontinuiran i stabilan rad sistema. Održavanje ovih nefunkcionalnih zahtjeva tokom razvoja i testiranja omogućava kreiranje aplikacije koja je ne samo funkcionalna, već i sigurna, brza i prilagođena potrebama krajnjih korisnika.

3.4. Tehnološki stek


Sistem je razvijen korištenjem savremenih web tehnologija i arhitekture bazirane na (eng. *MongoDB, Express, React, Node.js*) - *MERN* stacku. Frontend aplikacije koristi React za dinamičko i responzivno korisničko sučelje, uz podršku Tailwind CSS-a za brzi razvoj vizuelno konzistentnih komponenti. Axios omogućava komunikaciju sa backendom putem HTTP zahtjeva, dok React Router olakšava navigaciju između različitih stranica unutar aplikacije. Build proces se vrši pomoću Vite alata, koji optimizuje učitavanje i performanse aplikacije.

Backend je zasnovan na Node.js runtime-u i Express frameworku, pružajući REST API interfejs za frontend [4]. JWT tokeni i bcrypt hashiranje lozinki osiguravaju sigurnost autentifikacije i pohrane osjetljivih podataka. Funkcionalnost generisanja PDF dokumenata implementirana je korištenjem biblioteke Puppeteer, dok je za upravljanje procesom učitavanja fajlova korišten middleware Multer [5].

Podaci se trajno čuvaju u MongoDB Atlas bazi preko Mongoose ODM-a, omogućavajući efikasno čitanje i pisanje podataka. Eksterni servisi, poput Google Gemini AI i Jooble Job API-ja, integrisani su putem API poziva kako bi sistem mogao obogatiti funkcionalnost i pružiti dodatne informacije korisnicima.

Ova arhitektura omogućava modularan, skalabilan i održiv sistem, sposoban da podrži buduće nadogradnje i proširenja.

Kao što prikazuje Slika 3.4, sistem je jasno podijeljen na frontend (klijentsku stranu), backend (serversku stranu), sloj perzistencije podataka i eksterne servise, što omogućava modularnost, skalabilnost i jednostavno održavanje sistema.



Slika 3.4. Tehnološki stek dijagram

Prikazana arhitektura omogućava jasan tok podataka, razdvajanje odgovornosti između komponenti sistema i integraciju vještačke inteligencije u centralni poslovni proces aplikacije, čime se postiže fleksibilan, skalabilan i tehnološki savremen informacioni sistem [6].

3.4.1. Implementacione biblioteke i zavisnosti sistema

Pored osnovnog tehnološkog steka, realizacija aplikacije zahtijevala je korištenje niza specijalizovanih biblioteka i paketa koji obezbjeđuju dodatne funkcionalnosti, optimizaciju rada sistema i unapređenje korisničkog iskustva. Ove zavisnosti predstavljaju ključne komponente infrastrukturnog sloja aplikacije i direktno doprinose njenoj stabilnosti, sigurnosti i funkcionalnosti.

3.4.2. Frontend zavisnosti

Na frontend strani, sistem se oslanja na savremeni skup JavaScript biblioteka i alata koji omogućavaju izgradnju responzivnog, interaktivnog i modularnog korisničkog interfejsa, prilagođenog različitim uređajima i veličinama ekrana. Biblioteke React i React DOM predstavljaju temelj komponentno orijentisane arhitekture, omogućavajući razvoj ponovo upotrebljivih UI komponenti, jasno razdvajanje logike i prezentacionog sloja, te efikasno upravljanje stanjem aplikacije.

Za upravljanje rutama i navigacijom unutar aplikacije koristi se React Router, koji omogućava implementaciju višestranične logike unutar jedne (eng. *Single Page Application* - *SPA*) arhitekture, čime se postiže bolje korisničko iskustvo bez ponovnog učitavanja stranica [6].

Za stilizaciju i responzivni dizajn koristi se Tailwind CSS, utility-first CSS framework koji omogućava brzo i konzistentno oblikovanje korisničkog interfejsa uz visoku fleksibilnost prilagođavanja različitim uređajima. Pored navedenih tehnologija, u projektu se koriste i Axios za komunikaciju sa backend API-jem, Lucide React za ikone, te jsPDF i html2canvas za generisanje PDF dokumenata iz HTML sadržaja. Primjer konfiguracije frontend zavisnosti prikazan je u Kôdu 3.2.

```
{
  "react": "^19.2.0",
  "react-dom": "^19.2.0",
  "react-router-dom": "^7.9.6",
  "tailwindcss": "^4.1.17",
  "axios": "^1.13.2",
  "lucide-react": "^0.555.0",
  "jspdf": "^4.0.0",
  "html2canvas": "^1.4.1"
}
```

Kôd 3.2. Konfiguracija frontend zavisnosti

Komunikacija sa backend servisima realizuje se pomoću biblioteke Axios, koja obezbeđuje pouzdanu i efikasnu razmjenu podataka putem HTTP zahtjeva, uključujući obradu odgovora, grešaka i autentifikacionih tokena, čime se osigurava stabilnost i sigurnost klijentsko-serverske komunikacije. Biblioteka Lucide React koristi se za implementaciju vizuelnih ikona i UI elemenata, čime se unapređuje preglednost interfejsa, korisnička orijentacija i estetski kvalitet aplikacije [7].

Dodatno, sistem omogućava generisanje PDF dokumenata direktno na klijentskoj strani transformacijom HTML sadržaja u profesionalno formatirane dokumente. Na ovaj način korisnicima se omogućava jednostavno preuzimanje, čuvanje i dijeljenje CV dokumenata bez potrebe za dodatnim serverskim procesiranjem, čime se povećava efikasnost sistema i poboljšava ukupno korisničko iskustvo.

3.4.3. Backend zavisnosti

Serverski dio sistema implementiran je uz korištenje Express frameworka, koji omogućava efikasno upravljanje rutama i obradom HTTP zahtjeva. Mongoose biblioteka koristi se za rad sa MongoDB bazom podataka kroz objektno-dokumentno mapiranje, dok jsonwebtoken i bcryptjs obezbjeđuju mehanizme autentifikacije, autorizacije i sigurnog upravljanja korisničkim podacima [8]. Integracija vještačke inteligencije realizovana je putem paketa @google/generative-ai, koji omogućava komunikaciju sa Google Gemini AI servisom i naprednu obradu prirodnog jezika [7]. Biblioteka Puppeteer koristi se za serversko generisanje PDF dokumenata, dok Multer i pdf-parse omogućavaju upload, obradu i analizu fajlova u okviru aplikacije. Primjer konfiguracije backend zavisnosti prikazan je u Kôdu 3.3.


```
{
  "@google/generative-ai": "^0.24.1",
  "express": "^5.2.1",
  "mongoose": "^9.0.2",
  "jsonwebtoken": "^9.0.3",
  "bcryptjs": "^3.0.3",
  "puppeteer": "^24.34.0",
  "multer": "^2.0.2",
  "pdf-parse": "^1.1.1"
}
```

Kôd 3.3. Konfiguracija backend zavisnosti

Na ovaj način, korištene biblioteke i zavisnosti ne predstavljaju samo tehničke dodatke, već čine integralni dio arhitekture sistema, omogućavajući implementaciju funkcionalnosti kao što su analiza CV-a, inteligentne preporuke, generisanje dokumenata, sigurnosni mehanizmi i integracija eksternih AI servisa.

3.5. Dijagram slučajeja korištenja sistema

Dijagram slučajeja korištenja sistema prikazan na Slici 3.5 predstavlja funkcionalni model sistema iz perspektive krajnjeg korisnika.



Slika 3.5. Dijagram slučajeja korištenja iz perspektive korisnika

Centralni akter sistema je korisnik, koji kroz interakciju sa web aplikacijom ostvaruje pristup osnovnim funkcionalnostima sistema, uključujući registraciju i prijavu, kreiranje CV-a, upload postojećeg CV dokumenta, uređivanje sadržaja, pretragu poslova i preuzimanje CV-a u PDF formatu.

Sistem integriše i eksterne servise, pri čemu je Google Gemini AI prikazan kao spoljašnji akter zadužen za analizu CV-a i generisanje sadržaja, dok je servis Jooble predstavljen kao eksterni izvor podataka za pretragu oglasa za posao.

Dijagram jasno prikazuje odnose između funkcionalnosti sistema, uključujući include relaciju između procesa učitavanja CV-a i njegove AI analize, kao i extend relaciju između uređivanja sekcija CV-a i generisanja sadržaja pomoću vještačke inteligencije. Ovakav model omogućava jasan uvid u način interakcije korisnika sa sistemom i ulogu vještačke inteligencije u podršci procesu zapošljavanja.

3.5.1. Opis slučajeve korištenja

U Tabeli 3.6 predstavljen je slučaj korištenja Registracija korisnika.

Tabela 3.6. Dijagram slučajeve korištenja: Registracija korisnika

Naziv	Registracija korisnika
Akter	Korisnik
Opis	Omogućava kreiranje novog korisničkog naloga u sistemu.
Preduslovi	Nema
Postuslovi	Kreiran korisnički nalog i generisan JWT token.
Osnovni tok	1. Korisnik unosi email i lozinku. 2. Sistem validira podatke. 3. Provjera postojanja korisnika. 4. Hashiranje lozinke. 5. Kreiranje korisnika u bazi. 6. Generisanje JWT tokena. 7. Povrat uspješnog odgovora.
Alternativni tok	A1: Korisnik već postoji → sistem vraća grešku 400.

Ovaj slučaj korištenja opisuje proces kreiranja novog korisničkog naloga, uključujući validaciju podataka i generisanje autentifikacionog tokena.

U Tabeli 3.7 predstavljen je slučaj korištenja Prijava korisnika.

Tabela 3.7. Dijagram slučajeva korištenja: Prijava korisnika

Naziv	Prijava korisnika
Akter	Korisnik
Opis	Autentifikacija postojećeg korisnika u sistemu.
Preduslovi	Korisnik je registrovan
Postuslovi	Generisan JWT token, korisnik autentifikovan
Osnovni tok	1. Korisnik unosi email i lozinku. 2. Sistem pronalazi korisnika. 3. Upoređuje hash lozinke. 4. Generiše JWT token. 5. Vraća uspješan odgovor.
Alternativni tok	A1: Korisnik ne postoji → greška 404. A2: Pogrešna lozinka → greška 400.

Slučaj korištenja prikazuje postupak autentifikacije postojećeg korisnika i omogućava pristup funkcionalnostima sistema.

Tabeli 3.8 predstavljen je slučaj korištenja Učitavanje PDF CV-a.

Tabela 3.8. Dijagram slučajeva korištenja: Učitavanje PDF CV-a

Naziv	Učitavanje PDF CV-a
Akter	Korisnik
Opis	Omogućava učitavanje PDF CV dokumenta radi analize.
Preduslovi	Korisnik je prijavljen
Postuslovi	CV sačuvan, tekst ekstrahovan, analiza pohranjena u bazi
Osnovni tok	1. Korisnik učitava PDF dokument. 2. Sistem validira fajl. 3. Ekstrahuje tekst iz PDF-a. 4. Poziva AI analizu. 5. Sprema podatke u bazu. 6. Vraća potvrdu uspjeha.
Alternativni tok	A1: PDF bez teksta → greška 400. A2: Fajl nije poslan → greška 400.

Ovaj slučaj korištenja omogućava korisniku učitavanje CV dokumenta u PDF formatu radi dalje obrade i analize sadržaja.

U Tabeli 3.9 prikazan je slučaj korištenja AI analiza CV-a.

Tabela 3.9. Dijagram slučajeva korištenja: AI analiza CV-a

Naziv	AI analiza CV-a
Akter	Sistem (AI servis)
Opis	Analizira sadržaj CV-a i generiše preporuke i ocjenu kvaliteta.
Preduslovi	Tekst CV-a je uspješno ekstrahovan
Postuslovi	Generisana AI analiza (vještine, preporuke, score)
Osnovni tok	1. Sistem formira AI prompt. 2. Poziva Gemini API. 3. Parsira AI odgovor. 4. Generiše strukturirane podatke. 5. Vraća analizu sistemu.
Alternativni tok	A1: AI servis nedostupan → analiza sa osnovnim brojem bodova.

Slučaj korištenja opisuje automatsku analizu CV-a pomoću vještačke inteligencije s ciljem identifikacije vještina i generisanja preporuka.

U Tabeli 3.10 predstavljen je slučaj korištenja Pretraga poslova.

Tabela 3.10. Dijagram slučajeva korištenja: Pretraga poslova

Naziv	Pretraga poslova
Akter	Korisnik
Opis	Pretraga oglasa za posao na osnovu vještina iz CV-a.
Preduslovi	Korisnik je prijavljen, CV analiza postoji
Postuslovi	Lista relevantnih poslova prikazana korisniku
Osnovni tok	1. Sistem identifikuje vještine korisnika. 2. Kreira upit za API. 3. Provjerava cache. 4. Poziva Jooble API. 5. Formatira rezultate. 6. Prikazuje oglase korisniku.
Alternativni tok	A1: API nedostupan → prikaz keširanih rezultata. A2: Nema rezultata → prikaz generičkih preporuka.

Ovaj slučaj korištenja omogućava pronalazak relevantnih oglasa za posao na osnovu vještina prepoznatih u CV-u korisnika.

U Tabeli 3.11 predstavljen je slučaj korištenja Generisanje sadržaja CV-a.

Tabela 3.11. Dijagram slučajeva korištenja: Generisanje sadržaja CV-a

Naziv	Generisanje sadržaja CV-a
Akter	Korisnik
Opis	AI generiše profesionalni tekst za dijelove CV-a.
Preduslovi	Korisnik je prijavljen
Postuslovi	Generisan profesionalni tekst
Osnovni tok	1. Korisnik bira sekciju CV-a. 2. Sistem kreira AI prompt. 3. Poziva Gemini API. 4. Dobija generisan tekst. 5. Prikazuje tekst korisniku.
Alternativni tok	A1: Nedostaju ključne riječi → greška 400. A2: AI servis greška → greška 503.

Slučaj korištenja opisuje upotrebu AI servisa za generisanje profesionalnog sadržaja CV-a prema odabranoj sekciji.

U Tabeli 3.12 predstavljen je slučaj korištenja Preuzimanje CV-a kao PDF datoteke.

Tabela 3.12. Dijagram slučajeva korištenja: Preuzimanje CV-a kao PDF

Naziv	Preuzimanje CV-a kao PDF
Akter	Korisnik
Opis	Generisanje i preuzimanje CV dokumenta u PDF formatu.
Preduslovi	CV podaci postoje u sistemu
Postuslovi	PDF dokument uspješno preuzet
Osnovni tok	1. Korisnik zahtijeva PDF. 2. Sistem učitava CV podatke. 3. Generiše PDF dokument. 4. Šalje PDF korisniku.
Alternativni tok	A1: Greška u generisanju PDF-a → greška 500.

Ovaj slučaj korištenja omogućava korisniku generisanje i preuzimanje CV dokumenta u PDF formatu. Svaki slučaj korištenja formalno je opisan kroz definisane aktere, preduslove, postuslove, osnovni tok izvršavanja i alternativne tokove, čime se osigurava jasno razumijevanje funkcionalnosti sistema i njegovog ponašanja iz perspektive krajnjih korisnika i sistema.

4. PROJEKTOVANJE WEB APLIKACIJE

Za uspješnu izgrađivanju aplikacije tema treba biti dobro isplanirana. To podrazumjeva razumijevanje šta zadana tema zahtjeva, šta nudi, koje probleme rješava i na koji način. Da bi se razvoj pojednostavio, prije same implementacije aplikacije u odabranom programskom jeziku, izrađuju se dijagrami koji predstavljaju njen konceptualni model. Ovi dijagrami služe za lakše razumijevanje funkcionalnosti aplikacije i ubrzavaju proces implementacije. Također, dijagrami pojednostavljaju rad u timu, jer omogućavaju shvaćanje rada aplikacije svim članovima, bez neophodnog razumijevanja tehnologije u kojoj se aplikacija gradi. Dijagrami omogućuju vizualizaciju ključnih funkcionalnosti, identifikaciju međusobnih odnosa između entiteta te definisanje procesa interakcije korisnika sa sistemom. Takav pristup osigurava bolje planiranje, smanjuje mogućnost grešaka u implementaciji i omogućava efikasniji razvoj aplikacije prilagođene potrebama korisnika.

4.1. Arhitektura sistema

Sistem je razvijen prema principima troslojne (eng. *Three-Tier*) arhitekture, čime se postiže jasna separacija odgovornosti između klijentskog interfejsa, serverske logike i sloja za pohranu podataka [9].

- Prezantacioni sloj (Klijent):
 - Izgrađen pomoću React.js, odgovoran za korisnički interfejs i korisničko iskustvo.
 - Omogućava upload i pregled CV-a, prikaz rezultata AI analize i preporuka poslova.
- Logički sloj (Server):
 - Izgrađen pomoću Node.js i Express.js, rukuje API rutama, poslovnom logikom i komunikacijom sa eksternim AI servisima (Google Gemini API).
 - Implementira autentifikaciju korisnika, parsiranje i analizu CV-a, generisanje PDF dokumenta i pretragu poslova.
- Sloj podataka (Baza podataka):
 - MongoDB se koristi za trajno skladištenje korisničkih profila i CV podataka.
 - Održava strukturirane podatke o korisnicima, iskustvu, obrazovanju i analizama AI modela.

Troslojni pristup osigurava jasnu separaciju odgovornosti, što omogućava lakše održavanje, skalabilnost i bolju integraciju sa AI modulima i eksternim servisima.

4.2. Korištena tehnologija

Za razvoj aplikacije izabran je MERN stack, zbog jedinstvenog JavaScript okruženja i bogatog ekosistema. U Tabeli 4.1 prikazan je pregled korištenih tehnologija i slojeva sistema.

Tabela 4.1. Pregled korištenih tehnologija i slojeva sistema

Tehnologija	Sloj	Svrha
MongoDB	Sloj podataka	NoSQL baza pogodna za pohranu nestrukturisanih podataka kao što su sekcije CV-a
Express.js	Logički sloj	Minimalistički web framework za Node.js za izgradnju REST API-ja
React.js	Prezentacijski sloj	Frontend biblioteka za izradu dinamičkog, komponentno baziranog interfejsa
Node.js	Logički sloj	Okruženje za izvršavanje JavaScripta na serveru
Google Gemini API	Logički sloj	NLP servis za analizu CV-a i generisanje preporuka
Jooble API	Logički sloj	Eksterni servis za agregaciju i pretragu poslova
Puppeteer	Logički sloj	Generisanje PDF verzije CV-a sa servera za vizuelnu konzistentnost

Kombinacija ovih tehnologija omogućava razvoj skalabilnog, responzivnog i inteligentnog sistema koji korisnicima pruža real-time analizu CV-a i personalizovane preporuke poslova.

4.3. Model podataka i dijagrami

Za funkcionisanje aplikacije ključno je definisati model podataka, kako za korisnike, tako i za CV i rezultate analize. Model podataka definira način pohrane, organizacije i međusobne povezanosti podataka u sistemu. Aplikacija koristi MongoDB bazu podataka, a ključni entiteti su User, CV i JobCache. Implementacija modela User u okviru sistema za upravljanje podacima prikazana je u Kôdu 4.1.

```
import mongoose from 'mongoose';

const userSchema = new mongoose.Schema({
  email: {
    type: String,
```

```

        required: true,
        unique: true,
      },
      password: {
        type: String,
        required: true,
      },
      resetPasswordToken: String,
      resetPasswordExpire: Date,
    }, { timestamps: true });

const User = mongoose.model('User', userSchema);

export default User;

```

Kôd 4.1. User model

Entitet User predstavlja registrovanog korisnika sistema. Sadrži osnovne podatke o korisniku i podatke za autentifikaciju. Implementacija modela CV model u okviru sistema za upravljanje podacima prikazana je u Kôdu 4.2.

```

import mongoose from 'mongoose';

const cvSchema = new mongoose.Schema({
  user: {
    type: mongoose.Schema.Types.ObjectId,
    ref: 'User',
    required: true,
  },
  fileName: String,
  filePath: String,
  parsedText: String,
  analysis: {
    score: Number,
    suggestions: [String],
    skills: [String],
  },
}, { timestamps: true });

const CV = mongoose.model('CV', cvSchema);

export default CV;

```

Kôd 4.2. CV model

Entitet CV predstavlja korisnikov biografski dokument. Sadrži lične podatke, iskustvo, obrazovanje i rezultate AI analize. Implementacija modela JobCache u okviru sistema za upravljanje podacima prikazana je u Kôdu 4.3.

```

// ... inside /jobs route handler ...
const jobs = rawJobs.map((job, index) => ({
  id: job.id || index,

```

```
title: job.title,  
company: job.company || "Unknown",  
location: job.location,  
link: job.link,  
logo: null // Jooble doesn't provide logos in the basic API  
})).slice(0, 10);
```

Kód 4.3. Job model

Entitet JobCache se koristi za keširanje rezultata pretrage poslova radi optimizacije performansi i smanjenja broja poziva eksternim API-jima.

Kako bi se preciznije opisala aplikacija, u nastavku su prikazani dijagrami koji detaljno prikazuju sve akcije unutar aplikacije.

4.3.1. Strukturalni UML dijagrami

Strukturalni UML (engl. *Unified Modelling Language*) dijagrami su vizualne reprezentacije koje prikazuju statičke aspekte sistema, uključujući njegove klase, objekte, komponente i njihove međusobne odnose, pružajući jasan pregled arhitekture sistema. Strukturalni UML dijagrami prikazuju kako je sistem organizovan i kako se njegove komponente međusobno povezuju. Pokazuju klase, objekte i njihove odnose, tako da se arhitektura sistema može bolje razumjeti. To su:


- dijagram klasa,
- dijagram komponenti,
- dijagram paketa,
- dijagram objekata,
- dijagram složene strukture,
- dijagram razmještaja,
- profilni dijagram.

Od navedenih dinamičkih dijagrama u nastavku je detaljnije opisan klasni dijagram.

4.3.2. Klasni dijagram

Najčešće korišteni UML dijagram je dijagram klasa. On je osnovni element svih objektno-orijentisanih softverskih sistema. Koriste se da se prikaze statička struktura sistema, pokazujući klase sistema, njihove metode i atribute.

Klasni dijagram razvijenog sistema je prikazan na Slici 4.1.



Slika 4.1. Klasni dijagram

Klasni dijagram također pomaže da se identifikuju odnosi između različitih klasa ili objekata.


4.3.3. Bihevijoralni UML dijagrami

Behavijoralni UML dijagrami su vizualne reprezentacije koje prikazuju dinamičke aspekte sistema, fokusirajući se na način na koji objekti međusobno interaguju i kako se njihovo ponašanje mijenja tokom vremena kao odgovor na određene događaje ili akcije korisnika. Ovi dijagrami omogućavaju detaljno razumijevanje toka aktivnosti unutar sistema, identifikaciju ključnih interakcija, te olakšavaju analizu procesa i otkrivanje potencijalnih problema u dizajnu softvera prije implementacije. To su:

- dijagram aktivnosti,
- dijagram stanja,
- dijagram interakcije,
- dijagram slučajeva upotrebe.

Od navedenih dinamičkih dijagrama u nastavku je detaljnije opisan sekvencijalni dijagram koji je podkategorija dijagrama interakcije.


Sekvencijalni dijagram prikazuje interakciju između objekata u sekvencijalnom redoslijedu, tj. redoslijedu u kojem se ove interakcije dešavaju. Ovi dijagrami su široko korišteni od strane poslovnih ljudi i programera za dokumentovanje i razumijevanje zahtjeva za nove i postojeće sisteme.



Na Slici 4.2 prikazan je sekvencijalni dijagram koji ilustruje vremenski redoslijed izvršavanja operacija u sistemu, kao i međusobnu interakciju između korisnika, aplikacionog sistema i baze podataka.

ER (eng. *Entity-Relationship*) model predstavlja konceptualni model podataka koji se koristi za grafički prikaz strukture baze podataka pomoću entiteta, atributa i relacija između njih. Ovaj model omogućava lakše razumijevanje složenih sistema i predstavlja

osnovu za implementaciju baze podataka. Na Slici 4.3 prikazan je ER dijagram sistema za obradu biografija koji se sastoji od tri entiteta: Korisnik, CV i Biografija. Entitet Korisnik sadrži podatke o registrovanim korisnicima sistema, dok entiteti CV i Biografija predstavljaju dokumente i biografije koje korisnici kreiraju ili učitavaju u sistem. Između entiteta Korisnik i CV, kao i između Korisnik i Biografija, definisana je relacija 1:N, što znači da jedan korisnik može imati više CV-ova i više biografija. Ovakva struktura omogućava efikasno upravljanje korisničkim podacima i njihovim dokumentima.



Slika 4.3. ER dijagram

Korištenjem ER dijagrama omogućeno je jasno sagledavanje strukture baze podataka, odnosa između entiteta i njihove kardinalnosti, što olakšava razumijevanje sistema i predstavlja osnovu za implementaciju baze podataka u odabranoj tehnologiji.

5. IMPLEMENTACIJA WEB APLIKACIJE


U ovom poglavlju prikazan je proces implementacije funkcionalnosti web aplikacije za kreiranje i analizu CV-a te personalizovanu preporuku poslova.

5.1. Korištene tehnologije

Kao što je navedeno u poglavlju 3.4 aplikacija je razvijena korištenjem MERN steka, što omogućava skalabilnost, modularnost i jasnu podjelu odgovornosti između klijentske i serverske strane.

5.1.1. Frontend tehnologije

Klijentski dio aplikacije razvijen je korištenjem React biblioteke uz Vite razvojno okruženje, koje omogućava brzo pokretanje aplikacije i efikasno upravljanje zavisnostima. Za upravljanje navigacijom između stranica koristi se React Router DOM, dok je stanje autentifikacije korisnika centralizovano putem React Context API-ja. Na Slici 5.1 prikazan je izgled korisničkog interfejsa.



Slika 5.1. Korisnički interfejs aplikacije


Vizuelni izgled aplikacije realizovan je pomoću Tailwind CSS frameworka, koji omogućava responzivan i konzistentan dizajn korisničkog interfejsa. Komunikacija sa backend servisima ostvarena je korištenjem Axios biblioteke, dok je Lucide React korišten za prikaz modernih i ujednačenih ikona.

5.1.2. Backend tehnologije

Serverski dio aplikacije implementiran je pomoću Node.js runtime okruženja i Express.js frameworka. MongoDB baza podataka koristi se za trajnu pohranu podataka, uz Mongoose ODM koji omogućava objektno-dokumentni pristup bazi. Sigurnost i autentifikacija korisnika realizovane su pomoću JWT tokena i bcryptjs biblioteke za

hashiranje lozinki. Integracija vještačke inteligencije ostvarena je korištenjem Google Gemini LLM-a putem @google/generative-ai SDK-a [3]. Rad sa PDF dokumentima obuhvata korištenje Multer biblioteke za upload fajlova, pdf-parse za ekstrakciju teksta te Puppeteer za serversko generisanje PDF dokumenata.

Za pretragu poslova koristi se eksterni Jooble API. Aplikacija je zasnovana na klijent-server arhitekturi. Klijentska aplikacija izvršava se u web pregledniku korisnika i zadužena je za interakciju sa sistemom i prikaz podataka. Serverska aplikacija obrađuje poslovnu logiku, upravlja autentifikacijom, komunicira sa bazom podataka i eksternim servisima. Na Slici 5.2 prikazana je sojevita arhitektura backend sistema.



Slika 5.2. Slojevita arhitektura backend sistema

Komunikacija između klijenta i servera odvija se putem RESTful API poziva korištenjem HTTP protokola i JSON formata podataka.

5.2. Implementacija backend dijela

Backend je odgovoran za obradu zahtjeva koji dolaze sa klijentske strane, upravljanje autentifikacijom korisnika, rad sa bazom podataka, kao i integraciju sa eksternim servisima. Arhitektura sistema je organizovana prema MVC (eng. *Model-View-Controller*) pristupu, čime se postiže jasna podjela odgovornosti, bolja čitljivost kôda i jednostavnije održavanje aplikacije.

5.2.1. Autentifikacija i autorizacija

Autentifikacija korisnika implementirana je korištenjem JWT mehanizma. Tokom registracije korisnika lozinka se hashira pomoću bcrypt biblioteke i pohranjuje u bazu podataka. Prilikom prijave vrši se poređenje hashiranih vrijednosti, nakon čega se generiše JWT token. U Kôdu 5.1 prikazan je middleware za autorizaciju.

```
import jwt from 'jsonwebtoken';

const auth = async (req, res, next) => {
  try {
    const token = req.headers.authorization.split(" ")[1];

    let decodedData;

    if (token) {
      decodedData = jwt.verify(token, process.env.JWT_SECRET);
      req.userId = decodedData?.id;
    }

    next();
  } catch (error) {
    console.log(error);
    res.status(401).json({ message: 'Unauthenticated' });
  }
};

export default auth;
```

Kôd 5.1. Middleware za autorizaciju

Ovaj middleware provjerava JWT token u zaglavlju zahtjeva kako bi potvrdio identitet korisnika prije nego što dozvoli pristup zaštićenim rutama.

Primjer implementacije autentifikacijske rute za prijavu korisnika prikazan je u Kôdu 5.2.

```
import express from 'express';
import bcrypt from 'bcryptjs';
import jwt from 'jsonwebtoken';
import User from '../models/User.js';

const router = express.Router();

// REGISTER
router.post('/register', async (req, res) => {
  try {
    const { email, password } = req.body;

    const existingUser = await User.findOne({ email });
    if (existingUser) return res.status(400).json({ message:
      'User already exists' });
```

```

    const hashedPassword = await bcrypt.hash(password, 12);
    const result = await User.create({ email, password:
hashedPassword });

    const token = jwt.sign({ email: result.email, id: result._id },
process.env.JWT_SECRET, { expiresIn: '1h' });

    res.status(200).json({ result, token });
  } catch (error) {
    res.status(500).json({ message: 'Something went wrong' });
  }
});

// LOGIN
router.post('/login', async (req, res) => {
  try {
    const { email, password } = req.body;

    const existingUser = await User.findOne({ email });
    if (!existingUser) return res.status(404).json({ message:
'User not found' });

    const isPasswordCorrect = await bcrypt.compare(password,
existingUser.password);
    if (!isPasswordCorrect) return res.status(400).json({ message:
'Invalid credentials' });

    const token = jwt.sign({ email: existingUser.email,
id: existingUser._id }, process.env.JWT_SECRET,

    { expiresIn: '1h' });

    res.status(200).json({ result: existingUser, token });
  } catch (error) {
    res.status(500).json({ message: 'Something went wrong' });
  }
});
// ... (export default router)

```

Kôd 5.2. Autentifikacijske rute

Ove rute obrađuju registraciju korisnika (kreiranje novog korisnika s heširanom lozinkom) i prijavu (provjeru korisničkih podataka i izdavanje JWT tokena).

5.2.2. Integracija pretrage poslova

Sistem omogućava personalizovanu pretragu poslova na osnovu vještina prepoznatih u CV-u korisnika. Umjesto trajnog čuvanja oglasa, sistem djeluje kao posrednik između korisnika i Jooble API-ja. Primjer implementacije logike za pretragu poslova prikazan je

u Kôdu 5.3. Na osnovu identifikovanih vještina iz analiziranog CV-a formira se upit koji se koristi za slanje zahtjeva eksternom API servisu za pretragu poslova.

```
// Filter out "General" and take top 2 real skills
const validSkills = targetCV.analysis.skills.filter
(s => s !== "General");
if (validSkills.length > 0) {
    query = validSkills.slice(0, 2).join(' ');
}
// Call Jooble API...
const response = await axios.post(joobleUrl,
{ keywords: query, location: 'Bosnia and Herzegovina' });
```

Kôd 5.3. Logika pretrage poslova

Rezultati se keširaju u memoriji u trajanju od jednog sata kako bi se smanjio broj poziva prema eksternom API-ju.

5.3. Implementacija frontend dijela

Frontend dio aplikacije implementiran je korištenjem savremenih web tehnologija s ciljem postizanja responzivnog, intuitivnog i korisnički orijentisanog interfejsa. Fokus razvoja bio je na jednostavnosti korištenja, jasnoći prikaza informacija i efikasnoj interakciji korisnika sa sistemom. Frontend omogućava korisnicima upload i pregled CV dokumenata, vizualni prikaz rezultata AI analize, upravljanje ličnim podacima, te pregled i selekciju preporučenih poslova kroz interaktivno korisničko okruženje. Frontend dio aplikacije implementiran je korištenjem savremenih web tehnologija, s ciljem obezbjeđivanja responzivnog i intuitivnog korisničkog interfejsa. Omogućava korisnicima jednostavnu interakciju sa sistemom, pregled rezultata AI analize i pristup personalizovanim preporukama poslova.

5.3.1. Rutiranje i zaštita stranica

Rutiranje u aplikaciji definisano je u glavnoj App.jsx komponenti. Zaštićene stranice dostupne su isključivo autentifikovanim korisnicima putem ProtectedRoute komponente. U Kôdu 5.4 prikazane su definicije ruta.

```
<Route path='app' element={<ProtectedRoute><Layout /></ProtectedRoute>}>
  <Route index element={<Welcome />} />
  <Route path='dashboard' element={<Dashboard />} />
  <Route path='builder/:resumeId' element={<ResumeBuilder />} />
</Route>
```

Kôd 5.4. Definicija ruta

Zaštićene stranice dostupne su isključivo autentifikovanim korisnicima putem ProtectedRoute komponente.

5.4. Komunikacija sa backend servisima

Komunikacija između frontend aplikacije i backend servisa realizovana je putem REST API poziva, koji su centralizovani u posebnom Axios servisu. Ovakav pristup omogućava bolju organizaciju kôda, lakše održavanje i jednostavnije upravljanje svim HTTP zahtjevima na jednom mjestu.

Implementiran je Axios interceptor koji automatski dodaje JWT token u zaglavlje svakog HTTP zahtjeva. Na taj način se obezbjeđuje da svi zaštićeni backend endpointi budu dostupni isključivo autentifikovanim korisnicima, bez potrebe za ručnim dodavanjem tokena u svaki pojedinačni API poziv. Token se preuzima iz lokalne memorije preglednika, gdje se sigurno čuva nakon uspješne prijave korisnika.

```
import axios from 'axios';

const API = axios.create({ baseURL: 'http://localhost:5000' });

// Interceptor to attach JWT token to every request
API.interceptors.request.use((req) => {
  if (localStorage.getItem('profile')) {
    req.headers.Authorization = `Bearer
    ${JSON.parse(localStorage.getItem('profile')).token}`;
  }
  return req;
});

export const signIn = (formData) => API.post('/auth/login', formData);
export const createResume = (data) => API.post('/api/resume', data);
// ... other endpoints
```

Kôd 5.5. Axios interceptor za autentifikaciju

Isječak Kôda 5.5 prikazuje način na koji frontend aplikacija implementira mehanizam automatske autentifikacije zahtjeva, osiguravajući sigurnu i konzistentnu komunikaciju sa backend servisima. Ovaj pristup povećava sigurnost sistema, smanjuje mogućnost grešaka u implementaciji i pojednostavljuje dalji razvoj aplikacije.

5.4.1. Automatsko čuvanje podataka

Kako bi se poboljšalo korisničko iskustvo, implementirana je funkcionalnost automatskog čuvanja podataka. Sistem detektuje promjene u sadržaju CV-a i nakon određenog vremenskog intervala automatski sprema podatke u bazu.

```
// Trigger auto-save when cvData changes (debounced)
useEffect(() => {
  // Skip if data hasn't been loaded yet for existing resumes
  if (resumeId !== 'new' && !dataLoadedRef.current) return;

  // Clear existing timeout
  if (autoSaveTimeoutRef.current) {
    clearTimeout(autoSaveTimeoutRef.current);
```



```

    }

    // Set new timeout for auto-save (3 seconds after last change)
    autoSaveTimeoutRef.current = setTimeout(() => {
      // Only save if there's at least a name
      if (cvData.personal.fullName) {
        saveResume();
      }
    }, 3000);

    return () => {
      if (autoSaveTimeoutRef.current) {
        clearTimeout(autoSaveTimeoutRef.current);
      }
    };
  }, [cvData, saveResume, resumeId]);

```

Kôd 5.6. Auto-save logika

Isječak Kôda 5.6 demonstrira sofisticirano upravljanje stanjem korištenjem `useEffect` i `setTimeout` za automatsko spremanje napretka korisnika nakon što korisnik prestane tipkati.

5.4.2. Generisanje sadržaja pomoću AI

Korisnik može koristiti AI servis za generisanje profesionalnog sadržaja unutar CV-a, uključujući lične sažetke, opise radnog iskustva i profesionalne profile. Ova funkcionalnost posebno pomaže korisnicima koji nemaju jasnu ideju kako da predstave svoje vještine, iskustvo i lične kvalitete na profesionalan i strukturiran način.

```

const generateSummary = async () => {
  if (!cvData.personal.fullName)
    return alert("Unesite ime i prezime prvo.");

  setGenerating(true);
  try {
    const { data } = await api.generateContent({
      section: 'professional_summary',
      keywords: cvData.personal.fullName +
        " " + (cvData.experience[0]?.title || '')
    });

    setCvData(prev => ({
      ...prev,
      personal: { ...prev.personal, summary: data.content }
    }));
  } catch (error) {
    console.error(error);
    alert("ŠGreka pri generisanju žsadrāja.");
  } finally {
    setGenerating(false);
  }
}

```

```
}  
};
```

Kôd 5.7. Generisanje AI sadržaja

Funkcija prikazana u Kôdu 5.7 pokazuje kako frontend interaguje sa backend AI uslugom kako bi generisao sadržaj za korisnika.

5.4.3. Generisanje i preuzimanje PDF dokumenta

Na osnovu unesenih podataka, sistem omogućava automatsko generisanje CV dokumenta u PDF formatu. HTML struktura kreiranog CV-a sa frontenda šalje se serveru, gdje se pomoću Puppeteer biblioteke vrši serversko renderovanje i generisanje PDF dokumenta. Na taj način se obezbjeđuje visoka vizuelna konzistentnost, tačan prikaz dizajna i profesionalan izgled finalnog dokumenta, nezavisno od uređaja i preglednika koji korisnik koristi.

Nakon generisanja, PDF dokument se vraća frontend aplikaciji u obliku binarnih podataka, koji se zatim obrađuju i pretvaraju u fajl spreman za preuzimanje. Sistem automatski pokreće preuzimanje dokumenta u pregledniku, čime se korisniku omogućava jednostavno spremanje CV-a na lokalni uređaj bez dodatnih koraka.

```
const exportPDF = async () => {  
  
  try {  
    setGenerating(true);  
    const input = document.getElementById('cv-preview-content');  
    const html = input.outerHTML; // Get HTML of the resume  
  
    // Request PDF from server (sending HTML structure)  
    const response = await api.downloadPDF({  
      html,  
      css: resumeStyles  
    });  
  
    // Create Blob from response and trigger download  
    const blob = new Blob([response.data],  
      { type: 'application/pdf' });  
    const url = window.URL.createObjectURL(blob);  
    const link = document.createElement('a');  
    link.href = url;  
    link.download =  
      `Resume-${cvData.personal.fullName} || 'UsingCVBuilder'.pdf`;  
    document.body.appendChild(link);  
    link.click();  
  
    // Cleanup  
    window.URL.revokeObjectURL(url);  
  } catch (err) {  
    console.error("PDF Export Error:", err);  
  } finally {
```


```

        setGenerating(false);
    }
};

```

Kôd 5.8. Preuzimanje PDF dokumenta

Kôd 5.8 prikazuje način na koji aplikacija obrađuje binarne podatke dobijene sa servera, kreira odgovarajući Blob objekat, generiše privremeni URL i inicira preuzimanje PDF fajla u pregledniku ili memoriji računara.



Slika 5.3. Preuzimanje kreiranog PDF-a

Ovakav pristup omogućava sigurno, brzo i efikasno preuzimanje generisanih dokumenata, uz minimalno opterećenje korisničkog sistema. Nakon što korisnik unese lične podatke o sebi, klikom na dugme 'Spremi' generiše mu se PDF koji je prikazan na Slici 5.3.

5.4.4. Sigurnosni aspekti sistema

Sistem implementira osnovne sigurnosne mjere, uključujući hashiranje lozinki, zaštitu ruta, korištenje JWT tokena i pohranu osjetljivih podataka u environment varijable kao što je prikazano u Kôdu 5.9.

```
// Hash the password with a "salt round" of 12
const hashedPassword = await bcrypt.hash(password, 12);

// Create the user with the hashed password
const result = await User.create({ email, password: hashedPassword });
```

Kôd 5.9. Heširanje lozinke

Ovim pristupom osigurana je zaštita korisničkih podataka i integritet sistema.

5.5. Analiza rada platforme


Analiza rada web aplikacije obavljena je kroz detaljan pregled pojedinačnih slučajeva korištenja, pri čemu su identifikovani akteri, opisani tokovi procesa i navedene povratne informacije ili akcije, koje mogu imati pozitivan ili negativan ishod. Pored toga, posebno je obrađena interakcija između korisnika i sistema, uključujući moguće greške, kašnjenja ili nejasnoće u izvršavanju funkcionalnosti. Svaki scenario je detaljno dokumentovan, a posebna pažnja posvećena je identifikaciji potencijalnih problema koji mogu uticati na korisničko iskustvo, sigurnost podataka i efikasnost operacija.

Na osnovu prikupljenih podataka, izvršena je evaluacija funkcionalnih i nefunkcionalnih zahtjeva, uključujući brzinu odgovora sistema, jednostavnost navigacije, intuitivnost interfejsa i pouzdanost u radu. Takođe, razmatrani su i slučajevi integracije sa vanjskim servisima i bazama podataka, kako bi se osigurala kompatibilnost i kontinuitet poslovnih procesa. Zaključci analize pružaju osnovu za dalja poboljšanja i optimizaciju aplikacije, uključujući implementaciju dodatnih funkcionalnosti, unapređenje sigurnosnih mjera i prilagođavanje korisničkog interfejsa specifičnim potrebama ciljne grupe. Preporučene mjere uključuju testiranje performansi, kontinuirano praćenje korisničkih povratnih informacija i iterativno unapređivanje sistema, što osigurava održivost i skalabilnost aplikacije u budućem razvoju.

Slučaj korištenja 1: Registracija na sistem

- Naziv SK: Prijava na sistem,
- Akteri SK: Korisnik,
- Učesnici SK: Akter i sistem,
- Preduslov: Korisnik prvi put pristupa aplikaciji,
- Osnovni scenarij SK:
 - Akter unosi podatke,
 - Sistem provjerava da li su podaci validni,
 - Ukoliko su podaci validni, korisnik se unosi u bazu podataka i sistem prikazuje početnu stranicu,

- Sistem automatski prijavljuje korisnika i prikazuje početnu stranicu.
- Sporedni scenarij SK:
 - Podaci nisu tačni i korisniku se prikazuju poruke s greškomk kao što je prikazano na Slici 5.4.




Slika 5.4. Neuspješna registracija

Slučaj korištenja 2: Prijava na sistem

- Naziv SK: Prijava na sistem,
- Akteri SK: Korisnik,
- Učesnici SK: Akter i sistem,
- Preduslov: Korisnik ima registrovan račun,
- Osnovni scenarij SK:
 - Korisnik unosi email i lozinku,
 - Sistem validira podatke,
 - Sistem provjerava postojanje korisnika u bazi,
 - Sistem autentifikuje korisnika,
 - Sistem prikazuje početnu stranicu.

- Sporedni scenarij SK:
 - Pogrešni podaci za prijavu i prikaz poruke o grešci.

Izgled prijave na sistem prikazan je na Slici 5.5.




Slika 5.5. Prijava na sistem

Slučaj korištenja 3: Zaboravljena lozinka

- Naziv SK: Prijava na sistem,
- Akteri SK: Korisnik,
- Učesnici SK: Akter i sistem,
- Preduslov: Korisnik je prijavljen,
- Osnovni scenarij SK:
 - Korisnik pokušava da se prijavi u sistem unosom e-mail adrese i lozinke,
 - U slučaju da unesena lozinka nije tačna ili se korisnik ne sjeća lozinke, sistem prikazuje opciju za oporavak lozinke,
 - Korisnik bira opciju „Zaboravljena lozinka“,
 - Sistem od korisnika zahtijeva unos registrovane e-mail adrese,
 - Nakon unosa e-mail adrese, sistem šalje korisniku link ili instrukcije za postavljanje nove lozinke kao što je prikazano na Slici 5.6,
 - Korisnik putem dostavljenog linka unosi novu lozinku i potvrđuje promjenu,
 - Sistem ažurira lozinku u bazi podataka i omogućava korisniku ponovnu prijavu u sistem.

- Sporedni scenarij SK:
 - Podaci su tačni i korisniku se prikazuje početna stranica.




Slika 5.6. Zaboravljena lozinka

Nova lozinka za koju se korisnik odluči se potvrđuje putem mail adrese koju korisnik unese.

Slučaj korištenja 4: Uspješna prijava

- Naziv SK: Prijava,
- Akteri SK: Korisnik,
- Učesnici SK: Akter i sistem,
- Preduslov: Korisnik je uspješno prijavljen,
- Osnovni scenarij SK:
 - Akter se uspješno prijavljuje,
 - Sistem automatski preusmjerava korisnika na početnu stranicu, gdje su prikazane glavne funkcionalnosti i informacije dostupne korisniku, kao što je prikazano na Slici 5.7,
 - Tokom cijelog procesa, sistem osigurava sigurnost podataka, uključujući zaštitu lozinke i kreiranje sesije za korisnika.

- Sporedni scenarij SK:
 - Neispravna prijava.




Slika 5.7. Početna stranica

Slučaj korištenja 5: Upload PDF CV dokumenta

- Naziv SK: Upload CV-a,
- Akteri SK: Korisnik,
- Učesnici SK: Akter i sistem,
- Preduslov: Korisnik je prijavljen,
- Osnovni scenarij SK:
 - Akter bira PDF dokument,
 - Sistem validira format fajla,
 - Sistem učitava dokument kao što je prikazano na Slici 5.8,
 - Sistem parsira tekst iz PDF-a,
 - Dokument se pohranjuje u bazu podataka.

- Sporedni scenarij SK:
 - Neispravan format fajla ili greška pri učitavanju.




Slika 5.8. Učitavanje PDF CV dokumenta

Slučaj korištenja 6: Analiza CV-a pomoću AI sistema

- Naziv SK: AI analiza CV-a,
- Akteri SK: Sistem (AI),
- Učesnici SK: Sistem i AI servis,
- Preduslov: CV je uspješno učitani i parsiran,
- Osnovni scenarij SK:
 - Sistem priprema tekst CV-a,
 - Sistem šalje podatke AI modelu,
 - AI model analizira sadržaj,
 - Sistem prima strukturirane rezultate,
 - Rezultati se prikazuju korisniku kao što je prikazano na Slici 5.9.

- Sporedni scenarij SK:
 - Greška AI servisa i prikaz poruke o grešci.



Slika 5.9. Rezultati AI analize CV-a (preporuka poboljšanja)

Slučaj korištenja 7: Generisanje sadržaja CV-a

- Naziv SK: Generisanje sadržaja,
- Akteri SK: Korisnik,
- Učesnici SK: Akter, sistem i AI servis,
- Preduslov: Korisnik je prijavljen,
- Osnovni scenarij SK:
 - Akter bira sekciju CV-a,
 - Sistem šalje zahtjev AI servisu,
 - AI generiše profesionalni tekst,
 - Sistem prikazuje generisani sadržaj korisniku.

- Sporedni scenarij SK:
 - Neuspješno generisanje sadržaja.


Na Slici 5.10 prikazan je izgled predloška koji se koristi za kreiranje CV-a, uključujući polja za unos ličnih podataka, obrazovanja, radnog iskustva i drugih relevantnih informacija.

Slika 5.10. Generisanje sadržaja CV-a

Slučaj korištenja 8: Pretraga poslova

- Naziv SK: Pretraga poslova,
- Akteri SK: Korisnik,
- Učesnici SK: Akter i sistem,
- Preduslov: CV je analiziran,
- Osnovni scenarij SK:
 - Sistem koristi AI rezultate,
 - Sistem formira upit za pretragu,
 - Sistem poziva API servisa za poslove,
 - Sistem prikazuje listu poslova korisniku kao što je prikazano na Slici 5.11.

- Sporedni scenarij SK:
 - Neuspješna komunikacija sa API servisom.



Slika 5.11. Rezultati AI analize CV-a (preporuka poslova)

Slučaj korištenja 9: Preuzimanje CV-a u PDF formatu

- Naziv SK: Preuzimanje CV-a,
- Akteri SK: Korisnik,
- Učesnici SK: Akter i sistem,
- Preduslov: CV podaci postoje u sistemu,
- Osnovni scenarij SK:
 - Akter bira opciju preuzimanja,
 - Sistem generiše PDF dokument,
 - Sistem šalje fajl korisniku,
 - Korisnik preuzima dokument.
- Sporedni scenarij SK:
 - Greška pri generisanju PDF dokumenta.

Ovdje su prikazani samo neki od mnogih slučajeva korištenja. Na osnovu analize slučajeva korištenja može se zaključiti da sistem predstavlja integrisano, funkcionalno i inteligentno rješenje koje korisnicima omogućava efikasno kreiranje CV-a, njegovu automatsku analizu, AI unapređenje sadržaja i personalizovanu preporuku poslova. Sistem obezbjeđuje intuitivnu interakciju korisnika i pouzdanu obradu podataka, čime se značajno unapređuje proces profesionalnog predstavljanja i zapošljavanja.

6. ZAKLJUČAK

Ovaj završni rad je obuhvatio proces projektovanja i implementacije web platforme namijenjene za pomoć pri zapošljavanju. Razvoj i realizacija ove web aplikacije predstavlja odgovor na savremene izazove tržišta rada, koje karakterišu visoka konkurencija, digitalizacija procesa zapošljavanja i sve veća primjena automatizovanih sistema selekcije kandidata. U takvom okruženju, tradicionalni pristupi izradi CV-a i pretrazi poslova postaju nedovoljni, jer više ne odgovaraju kompleksnosti i dinamici modernih procesa zapošljavanja. Kandidati se suočavaju s problemima neadekvatnog predstavljanja vlastitih kompetencija, nedostatkom povratnih informacija o kvalitetu svojih prijava, kao i neefikasnom pretragom poslova koja se često zasniva na prostom podudaranju ključnih riječi, bez stvarnog razumijevanja značenja i konteksta.

U radu je predstavljen koncept i implementacija integrisane web platforme koja objedinjuje funkcionalnosti kreiranja profesionalnog CV-a, njegove inteligentne analize pomoću vještačke inteligencije, generisanja sadržaja i personalizovanih preporuka poslova. Time je uspostavljen jedinstven sistem koji korisniku pruža cjelovit rada, od unosa podataka i izrade dokumenta, preko analize kvaliteta sadržaja, do aktivne podrške u pronalasku relevantnih radnih pozicija. Ovakav pristup prevazilazi fragmentiranost postojećih rješenja, gdje su pojedine funkcionalnosti raspoređene na više nepovezanih alata i platformi.

Poseban značaj ovog rješenja ogleda se u primjeni vještačke inteligencije ne samo kao sredstva za automatizaciju, već kao inteligentnog asistenta korisniku. Integracijom Google Gemini AI servisa omogućena je napredna obrada prirodnog jezika, semantičko razumijevanje sadržaja CV dokumenata i generisanje smislenih, kontekstualno relevantnih preporuka. Na taj način, sistem ne funkcioniše isključivo na osnovu ključnih riječi, već razumije značenje pojmova, odnose između vještina, iskustava i profesionalnih uloga, čime se značajno povećava preciznost analize i preporuka.

Dodatna vrijednost sistema ogleda se u konceptu "nivelisanja terena" između kandidata i automatizovanih sistema selekcije (ATS). Dok se AI tehnologije već široko koriste na strani poslodavaca za filtriranje i rangiranje kandidata, ovim rješenjem slični alati se stavljaju i na raspolaganje kandidatima. Time im se omogućava da bolje razumiju zahtjeve tržišta rada, unaprijede strukturu i sadržaj svojih biografija i povećaju šanse za prolazak kroz automatizovane sisteme selekcije. Ovakav pristup predstavlja značajan iskorak ka pravednijem i transparentnijem digitalnom zapošljavanju.

Važan doprinos kreiranog sistema jeste i njena prilagođenost lokalnom kontekstu, kroz podršku za bosanski jezik i orijentaciju ka tržištu rada Bosne i Hercegovine. Time se rješava problem jezičke i kontekstualne neprilagođenosti globalnih alata, koji često ne nude adekvatnu podršku za manje jezike i lokalne specifičnosti tržišta rada. Na ovaj način sistem postaje praktično upotrebljiv alat za lokalne korisnike, studente, mlade profesionalce i osobe koje se nalaze u procesu profesionalne tranzicije.

Na osnovu implementiranih funkcionalnosti i ostvarene integracije vještačke inteligencije, može se zaključiti da predložena aplikacija predstavlja savremeno,

funkcionalno i korisnički orijentisano rješenje koje odgovara realnim potrebama osoba koje traže posao. Sistem ne samo da olakšava tehnički aspekt izrade CV-a, već aktivno doprinosi kvalitetu sadržaja, profesionalnom predstavljanju korisnika i efikasnijem povezivanju sa tržištem rada.

U budućem razvoju moguće je dodatno proširenje funkcionalnosti kroz uvođenje modula za praćenje prijava za posao, analitiku uspjeha prijave, personalizovane planove profesionalnog razvoja, kao i integraciju sa većim brojem platformi za zapošljavanje. Također, daljim razvojem AI modela moguće je unaprijediti preciznost analize, personalizaciju preporuka i adaptivno učenje sistema na osnovu korisničkog ponašanja i povratnih informacija.

7. LITERATURA

- [1] Daniel Bugl, *Modern Full-Stack Project*, Google Books, 2021. Dostupno na: <https://books.google.ba/books?hl=hr&lr=&id=eMoHEQAAQBAJ> [Posjećeno: oktobar 2025]
- [2] John Berryman, Alber Ziegler, *The Art and Science Building Large Language Model-Based Applications*, Google Books, 2025. Dostupno na: <https://books.google.ba/books?hl=hr&lr=&id=9EQvEQAAQBAJ> [Posjećeno: oktobar 2025]
- [3] *Integrating Large Language Models with near Real-Time Web Crawling for Enhanced Job Recommendation Systems*. Dostupno na: <https://www.mdpi.com/2073-431X/14/9/387> [Posjećeno: oktobar 2025]
- [4] OpenJS Foundation, Node.js Documentation. Dostupno na: <https://nodejs.org/en/docs/> [Posjećeno: oktobar 2025]
- [5] OpenJS Foundation, Express - Node.js web application framework. Dostupno na: <https://expressjs.com/> [Posjećeno: oktobar 2025]
- [6] Meta Platforms, React Documentation. Dostupno na: <https://react.dev/> [Posjećeno: oktobar 2025]
- [7] Google LLC, Gemini API Documentation. Dostupno na: <https://ai.google.dev/> [Posjećeno: oktobar 2025]
- [8] Automattic, Mongoose Documentation. Dostupno na: <https://mongoosejs.com/> [Posjećeno: oktobar 2025]
- [9] CV Retrieval / Job Matching using embeddings, ScienceDirect. Dostupno na: <https://www.sciencedirect.com/science/article/abs/pii/S0885230817302851> [Posjećeno: oktobar 2025]